

Technická univerzita v Košiciach
Fakulta elektrotechniky a informatiky

Využitie transformerov v detekcii toxicity na sociálnych sieťach

Bakalárska práca

Technická univerzita v Košiciach
Fakulta elektrotechniky a informatiky

Využitie transformerov v detekcii toxicity na sociálnych sieťach

Bakalárska práca

Študijný program: Intelligentné systémy
Študijný odbor: Informatika
Školiace pracovisko: Katedra kybernetiky a umelej inteligencie (KKUI)
Školiteľ: prof. Ing. Kristína Machová, PhD.
Konzultant:

Košice 2026

Artem Mykhailichenko

Abstrakt v SJ

Táto bakalárska práca sa zaoberá využitím transformerových modelov na detekciu toxicity v online komentároch. Cieľom práce bolo natrénovať a porovnať štyri transformerové modely (BERT, RoBERTa, DistilBERT a ALBERT) a tri klasické baseline modely (Logistic Regression, Linear SVM a Naive Bayes) na datasete Jigsaw Toxic Comment Classification Challenge. Najlepší výsledok dosiahol model BERT s hodnotou F1-score 0,8427, čo predstavuje relatívne zlepšenie o 10,2 % oproti najlepšiemu baseline modelu. Model DistilBERT pri zachovaní 98,8 % kvality modelu BERT ponúka takmer dvojnásobnú rýchlosť inferencie (3,64 ms oproti 6,78 ms). Testovanie na externých datasetoch Civil Comments a TweetEval Offensive odhalilo relatívny pokles F1-score v rozmedzí 36,3–38,7 % na datasete Civil Comments a 21,7–24,3 % na datasete TweetEval Offensive pri prechode na inú doménu, pričom transformerové modely si udržali výrazný náskok pred baseline modelmi. Manuálna analýza chýb identifikovala systematické obmedzenia modelu pri detekcii implicitných foriem toxicity. Výsledky potvrdzujú, že transformerové modely predstavujú efektívny nástroj na automatickú detekciu online toxicity, pričom ich hlavným obmedzením zostáva citlivosť na doménu tréningových dát.

Kľúčové slová

detekcia toxicity, transformerové modely, BERT, klasifikácia textu, spracovanie prirodzeného jazyka

Abstrakt v AJ

This bachelor's thesis focuses on the use of transformer models for toxicity detection in online comments. The goal was to train and compare four transformer models (BERT, RoBERTa, DistilBERT, ALBERT) and three classical baseline models (Logistic Regression, Linear SVM, Naive Bayes) on the Jigsaw Toxic Comment Classification Challenge dataset. The best result was achieved by BERT with an F1-score of 0.8427, representing a relative improvement of 10.2 % over the best baseline model. DistilBERT, while retaining 98.8 % of BERT's quality, offers nearly twice the inference speed (3.64 ms vs 6.78 ms). Testing on external datasets Civil Comments and TweetEval Offensive revealed a relative F1-score drop of 36.3–38.7 % on Civil Comments and 21.7–24.3 % on TweetEval Offensive when transferring to a new domain, while transformer models maintained a significant advantage over baseline models. Manual error analysis identified systematic limitations of the model in detecting implicit forms of toxicity. The results confirm that transformer models represent an effective tool for automatic online toxicity detection, with their main limitation being sensitivity to the domain of training data.

Klíčové slová v AJ

toxicity detection, transformer models, BERT, text classification, natural language processing

78055

TECHNICKÁ UNIVERZITA V KOŠICIACH
FAKULTA ELEKTROTECHNIKY A INFORMATIKY
Katedra kybernetiky a umelej inteligencie

ZADANIE BAKALÁRSKEJ PRÁCE

Študijný odbor: **Informatika**
Študijný program: **Inteligentné systémy**

Názov práce:

Využitie transformerov v detekcii toxicity na sociálnych sieťach

The use of transformers in toxicity detection on social networks

Študent: **Artem Mykhailichenko**
Školiteľ: **prof. Ing. Kristína Machová, PhD.**
Školiace pracovisko: **Katedra kybernetiky a umelej inteligencie**
Konzultant práce:
Pracovisko konzultanta:

Pokyny na vypracovanie bakalárskej práce:

1. Podat' stručný prehľad o probléme detekcie online toxicity.
2. Analyzovať súčasný stav v oblasti transformerov a zvoliť vhodné metódy pre danú úlohu.
3. Vyhľadať, analyzovať a pred-spracovať dáta pre danú úlohu.
4. Použiť zvolené metódy na naučenie modelov na detekciu toxicity.
5. Generované modely testovať a vyhodnotiť.
6. Vypracovať dokumentáciu podľa pokynov vedúcej práce.

Jazyk, v ktorom sa práca vypracuje: **slovenský**
Termín pre odovzdanie práce: **29.05.2026**
Dátum zadania bakalárskej práce: **31.10.2025**



prof. Ing. Liberios Vokorokos
prof. Ing. Liberios Vokorokos, PhD.
dekan fakulty

Čestné vyhlásenie

Vyhlasujem, že som záverečnú prácu vypracoval samostatne s použitím uvedenej odbornej literatúry, ako aj s využitím nástrojov generatívnej umelej inteligencie v súlade s Metodickým pokynom o záverečných a kvalifikačných prácach a Etickým kódexom študenta Technickej univerzity v Košiciach. Umelá inteligencia bola použitá ako podporný nástroj bez porušenia zásad akademickej etiky a autorskej integrity.

Košice 29. 5. 2026

.....

Vlastnoručný podpis

Podakovanie

Ďakujem vedúcej bakalárskej práce za poskytnutie študijných materiálov a odborné konzultácie, ktoré mi pomohli lepšie pochopiť tému a nasmerovali ma pri ďalšom postupe.

Predhovor

Téma tejto práce bola zvolená vzhľadom na rastúci význam automatizovanej moderácie online obsahu a aktuálnosť problematiky toxicity na sociálnych sieťach. Transformerové modely predstavujú v súčasnosti jeden z najefektívnejších prístupov k spracovaniu prirodzeného jazyka, čo ma motivovalo k hlbšiemu preskúmaniu ich možností pri detekcii toxických komentárov v online prostredí.

Obsah

Zoznam obrázkov	11
Zoznam tabuliek	12
Zoznam skratiek	13
1 Úvod	1
2 Formulácia úlohy	2
3 Teoretický základ riešenej problematiky	3
3.1 Online toxicita v digitálnom prostredí	3
3.1.1 Definícia online toxicity a jej formy	3
3.1.2 Problém online toxicity pre platformy a spoločnosť	5
3.1.3 Prehľad prístupov k automatickej detekcii	6
3.2 Hodnotiace metriky	7
3.2.1 Matica chýb	7
3.2.2 Accuracy, Precision, Recall a F1-score	8
3.2.3 ROC-AUC	9
3.3 Klasické metódy textovej klasifikácie	9
3.3.1 TF-IDF vektorizácia	9
3.3.2 Klasické klasifikátory a nevyváženosť tried	10
3.4 Transformerová architektúra	11
3.4.1 Mechanizmus self-attention	12
3.4.2 Architektúra encodera	12
3.4.3 Predtréning, fine-tuning a funkcia strát	13
3.5 Prehľad použitých modelov	14
3.5.1 BERT	14
3.5.2 RoBERTa	15
3.5.3 DistilBERT	15

3.5.4	ALBERT	15
3.6	Súvisiace práce	16
4	Experimenty a analýza výsledkov	22
4.1	Cieľ experimentálnej časti	22
4.2	Dataset Jigsaw a predspracovanie dát	22
4.3	Trénovanie transformerových modelov	23
4.3.1	Spoločná konfigurácia tréningu	23
4.3.2	BERT-base-uncased	25
4.3.3	RoBERTa-base	26
4.3.4	DistilBERT	27
4.3.5	ALBERT-base-v2	28
4.3.6	Porovnanie priebehu tréningu	29
4.4	Baseline modely	30
4.5	Hodnotenie a porovnanie všetkých modelov	32
4.5.1	Celkové porovnanie podľa F1-score	32
4.5.2	Kompromis medzi Precision a Recall	33
4.5.3	Praktické charakteristiky modelov	33
4.6	Testovanie trénovaných modelov na iných datasetoch	34
4.6.1	Externé datasety	34
4.6.2	Výsledky a interpretácia	35
4.7	Manuálna analýza chýb modelu BERT	38
4.7.1	Istota modelu pri chybach	38
4.7.2	Analýza FN podľa podtypov toxicity	38
4.7.3	Kategórie FN	39
4.7.4	Analýza FP	41
4.7.5	Závery analýzy chýb	42
5	Záver	43
	Zoznam literatúry	45

Zoznam obrázkov

3–1	Taxonómia foriem online toxicity	4
3–2	Architektúra jednej vrstvy encodera transformera	13
4–1	Priebeh tréovania transformerových modelov: F1-score (hore) a Loss (dole) na trénovacej a validačnej množine počas troch epoch	30
4–2	F1-score transformerových a baseline modelov na troch datasetoch: Jigsaw (trénovací), Civil Comments a TweetEval	37

Zoznam tabuliek

3–1	Matica chýb pre binárnu klasifikáciu	8
3–2	Porovnanie použitých transformerových modelov	16
4–1	Spoločné hyperparametre tréovania transformerových modelov	25
4–2	Priebeh tréovania modelu BERT podľa epoch	25
4–3	Finálne metriky modelu BERT na validačnej množine	26
4–4	Priebeh tréovania modelu RoBERTa podľa epoch	26
4–5	Finálne metriky modelu RoBERTa na validačnej množine	27
4–6	Priebeh tréovania modelu DistilBERT podľa epoch	27
4–7	Finálne metriky modelu DistilBERT na validačnej množine . . .	28
4–8	Priebeh tréovania modelu ALBERT podľa epoch	28
4–9	Finálne metriky modelu ALBERT na validačnej množine	29
4–10	Finálne metriky baseline modelov na validačnej množine	31
4–11	Porovnanie všetkých modelov na validačnej množine Jigsaw . . .	33
4–12	Praktické charakteristiky transformerových modelov	33
4–13	F1-score modelov na troch datasetoch	35
4–14	Doplnkové metriky modelov na externých datasetoch	36
4–15	Istota modelu BERT pri chybných predikciách	38
4–16	Miera vynechania podľa podtypu toxicity – model BERT	38

Zoznam skratiek

AMP	Automatic Mixed Precision
AUC	Area Under Curve
BiGRU	Bidirectional Gated Recurrent Unit
BiLSTM	Bidirectional Long Short-Term Memory
BiRNN	Bidirectional Recurrent Neural Network
CCT	Compact Convolutional Transformer
CNN	Convolutional Neural Network
CPU	Central Processing Unit
DSA	Digital Services Act
F1	F1-score (harmonický priemer Precision a Recall)
FN	False Negative
FP	False Positive
GB	Gigabyte
GPU	Graphics Processing Unit
IDF	Inverse Document Frequency
LDA	Latent Dirichlet Allocation
LR	Logistic Regression
LSA	Latent Semantic Analysis
LSTM	Long Short-Term Memory
MB	Megabyte
ms	milisekunda (millisecond)
NCP	Neural Classification Pipeline
NLP	Natural Language Processing
NSP	Next Sentence Prediction
RF	Random Forest
RNN	Recurrent Neural Network
ROC	Receiver Operating Characteristic
SVM	Support Vector Machine
TF	Term Frequency
TF-IDF	Term Frequency – Inverse Document Frequency
TN	True Negative
TP	True Positive

1 Úvod

Online toxicita predstavuje jeden z kľúčových problémov súčasných digitálnych platforiem. S rastúcim objemom obsahu na sociálnych sieťach sa manuálna moderácia stáva čoraz menej efektívnou, čo vytvára potrebu automatizovaných systémov detekcie toxického obsahu.

Vývoj metód automatickej detekcie toxicity prešiel od jednoduchých pravidlových systémov cez klasické modely strojového učenia až po moderné transformerové architektúry. Práve transformerové modely predstavujú jeden z najefektívnejších prístupov k spracovaniu prirodzeného jazyka a dosahujú vyššiu výkonnosť ako predchádzajúce metódy.

Cieľom tejto práce je preskúmať možnosti využitia transformerových modelov na detekciu toxicity v online komentároch. Na tento účel boli natréňované štyri transformerové modely (BERT, RoBERTa, DistilBERT a ALBERT) a tri klasické baseline modely (Logistic Regression, Linear SVM a Naive Bayes) na datasete Jigsaw Toxic Comment Classification Challenge. Modely boli následne vyhodnotené pomocou štandardných metrík a otestované na externých datasetoch Civil Comments a TweetEval Offensive s cieľom overiť ich schopnosť fungovať na dátach z iných domén.

Práca je štruktúrovaná nasledovne. Druhá kapitola formuluje úlohu práce. Tretia kapitola poskytuje teoretický základ, ktorý zahŕňa prehľad problematiky online toxicity, hodnotiace metriky, klasické metódy textovej klasifikácie, transformerovú architektúru, prehľad použitých modelov a prehľad súvisiacich výskumov v oblasti detekcie toxicity. Štvrtá kapitola opisuje experimentálnu časť práce vrátane predstavenia datasetu Jigsaw a predspracovania dát, tréňovania modelov, porovnania ich výsledkov, testovania na externých datasetoch a manuálnej analýzy chýb. Piata kapitola sumarizuje dosiahnuté výsledky, obmedzenia práce a možné smery ďalšieho výskumu.

2 Formulácia úlohy

V rámci riešenia bakalárskej práce sa majú postupne splniť nasledovné úlohy:

- Podat stručný prehľad o probléme detekcie online toxicity, jej formách a spoločenskom dopade.
- Analyzovať transformerové architektúry BERT, RoBERTa, DistilBERT a ALBERT a zvoliť vhodné metódy pre úlohu klasifikácie toxicity.
- Vyhladať a analyzovať datasety Jigsaw, Civil Comments a TweetEval Offensive vhodné pre tréovanie a testovanie modelov.
- Natrénovať štyri transformerové modely (BERT, RoBERTa, DistilBERT, ALBERT) a tri klasické baseline modely (Logistic Regression, Linear SVM, Naive Bayes) na datasete Jigsaw a porovnať ich výkonnosť.
- Otestovať natréované modely na externých datasetoch a vyhodnotiť ich výkonnosť pomocou metrík F1-score, accuracy, precision, recall a ROC-AUC.
- Vypracovať dokumentáciu v súlade s pokynmi vedúcej práce.

3 Teoretický základ riešenej problematiky

3.1 Online toxicita v digitálnom prostredí

V súčasnosti predstavujú digitálne platformy a sociálne siete hlavné prostredie verejnej komunikácie. Umožňujú okamžitú výmenu názorov v globálnom meradle, no zároveň vytvárajú podmienky pre šírenie online toxicity, ktorá sa stala jednou z kľúčových výziev moderného digitálneho prostredia. S rastúcim počtom používateľov a objemom obsahu sa tento problém každoročne zväčšuje, čo vytvára tlak na platformy, akademickú sféru aj legislatívu hľadať efektívne riešenia.


3.1.1 Definícia online toxicity a jej formy

Pod pojmom online toxicita sa rozumie široké spektrum negatívnych jazykových prejavov, ktoré narúšajú normy komunikácie, poškodzujú účastníkov diskusie alebo sú namierené proti konkrétnym osobám či skupinám. Na základe prehľadu odbornej literatúry [1] možno rozlíšiť nasledujúce základné formy online toxicity:

- **Nenávistné prejavy (hate speech)** — výrazy namierené proti ľuďom na základe rasy, pohlavia, sexuálnej orientácie, náboženstva alebo inej skupinovej príslušnosti. Ide o jednu z najhorších foriem toxicity, ktorá môže spôsobovať diskrimináciu aj mimo online prostredia.
- **Kyberšikana (cyberbullying)** — opakované cielené útoky vo forme urážok, vyhrážok alebo posmechu namierené voči konkrétnej osobe alebo skupine. Od ostatných foriem toxicity ju odlišuje predovšetkým systematickosť, zámer dlhodobu ubližovať konkrétnej obeti a nerovnováha síl medzi útočníkom a obeťou, ktorá sa nemôže ľahko brániť.
- **Vulgárna a expresívna lexika (obscene language)** — výrazy s agresívnym alebo sexuálnym obsahom. Nie každé použitie vulgárneho jazyka je automaticky toxické, čo predstavuje výzvu pre automatické systémy detekcie.

- **Osobné urážky (insults)** — priame útoky na vzhľad, schopnosti alebo súkromný život človeka, ktoré sú namierené voči konkrétnej osobe a nie voči skupine.
- **Vyhrážky (threats)** — výroky obsahujúce hrozbu fyzického alebo psychického násilia. Aj keď sú formulované nepriamo, môžu mať závažné psychologické dôsledky pre obeť.
- **Pasívna agresia** — skryté nepriateľské formulácie, ktoré formálne neporušujú pravidlá, no sú vnímané ako urážlivé.
- **Sarkazmus a irónia** — výroky, ktorých skutočný význam je opačný ako doslovné znenie, pričom sú použité s úmyslom zosmiešniť alebo uraziť. Tieto dve kategórie sa môžu navzájom prekrývať, keďže sarkazmus je často formou pasívnej agresie.

Vzťahy medzi jednotlivými formami online toxicity ilustruje nasledujúci diagram (obrázok 3–1), ktorý rozdeľuje toxicitu na explicitnú a implicitnú vetvu.



Obrázok 3–1 Taxonómia foriem online toxicity

Dôležité je rozlišovať medzi **explicitnou** a **implicitnou** online toxicitou. Explicitná toxicita obsahuje priame hrubé slová alebo otvorené útoky, ktoré automatické systémy dokážu pomerne ľahko rozoznať. Implicitná online toxicita sa naopak prejavuje nepriamo, prostredníctvom sarkazmu, irónie alebo pasívnej agresie, a predstavuje oveľa väčší problém pre automatickú detekciu. Dôležitú úlohu pri určovaní toxicity zohráva aj kontext, keďže rovnaký výrok môže byť toxický alebo nevinný v závislosti od vzťahu medzi účastníkmi, kultúrneho prostredia a komunikačnej platformy.

Práve závislosť od kontextu spôsobuje, že detekcia implicitnej toxicity patrí medzi najnáročnejšie úlohy v oblasti spracovania prirodzeného jazyka.

3.1.2 Problém online toxicity pre platformy a spoločnosť

Jedným z faktorov podporujúcich šírenie online toxicity je anonymita používateľov. V online prostredí, kde nie je identita používateľov priamo viditeľná, dochádza k zníženiu pocitu sociálnej zodpovednosti za vlastné vyjadrenia. Tento jav je v psychológii známy ako efekt deindividualizácie, čo znamená oslabenie sociálnych noriem v anonymnom digitálnom prostredí.

Ďalším faktorom sú odporúčacie systémy sociálnych sietí, ktoré sú optimalizované na interakciu používateľov. V dôsledku tejto optimalizácie sa obsah spôsobujúci silné emócie môže zobrazovať častejšie, čo môže nepriamo podporovať šírenie konfliktného a toxického obsahu.

Psychologické dôsledky online toxicity pre obete sú závažné a dobre zdokumentované. Podľa systematického prehľadu štúdií sa vystavenie kyberšikane spája s výskytom depresie, úzkosti a stresu, pričom depresia aj úzkosť boli potvrdené vo väčšine analyzovaných štúdií (depresia v 16 z 20, úzkosť v 12 z 15) [2]. Pri mladých ľuďoch sú tieto dôsledky osobitne výrazné, keďže digitálne prostredie umožňuje útočníkom zasiahnuť obeť kedykoľvek a kdekoľvek. Opakované vystavenie toxickému obsahu môže viesť k dlhodobým psychickým následkom a zníženiu ochoty zúčastňovať sa na verejných diskusiách.

Pre samotné platformy predstavuje online toxicita nielen reputačný, ale aj ekonomický problém. Investície do manuálnej moderácie sú nákladné a psychicky náročné pre moderátorov, ktorí sú denne vystavení toxickému obsahu. Zároveň nedostatočná moderácia môže viesť k odchodu používateľov a zníženiu dôveryhodnosti platformy.

V oblasti legislatívy sa v posledných rokoch objavujú medzinárodné snahy o reguláciu online obsahu. Európska únia prijala v roku 2022 Akt o digitálnych službách (Digital Services Act, DSA) [3], ktorý zavádza regulačný rámec pre veľké online platformy s cieľom obmedziť šírenie nelegálneho obsahu vrátane nenávistných prejavov.

Platformy sú povinné zavádzať mechanizmy na hlásenie a odstraňovanie škodlivého obsahu a sú vystavené finančným sankciám v prípade neplnenia týchto povinností. Doplnkom k DSA je Akt o umelej inteligencii (AI Act) [4], ktorý vstúpil do platnosti v roku 2024 a ktorého hlavná fáza presadzovania nadobúda účinnosť v auguste 2026. Tento akt zavádza regulačný rámec pre automatizované systémy analýzy obsahu vrátane nástrojov na detekciu toxicity.

Na rozdiel od týchto legislatívnych snáh sa však niektoré platformy uberajú opačným smerom. V januári 2025 spoločnosť Meta výrazne oslabila svoju politiku moderácie obsahu na platformách Facebook, Instagram a Threads, čím ukončila program nezávislého overovania faktov a obmedzila proaktívne odstraňovanie nenávistných prejavov. Podľa analýzy EOOH [5] bola toxicita voči ženám na Facebooku začiatkom roka 2025 približne o 30–40 % vyššia než v novembri 2024. Tento nárast sa začal už pred zmenou politiky, takže nesúvisí len s ňou. Ukazuje však, že toxický obsah na sociálnych sieťach je naďalej vážnym problémom a treba ho vedieť automaticky odhaľovať.

3.1.3 Prehľad prístupov k automatickej detekcii

Vývoj metód automatickej detekcie online toxicity prešiel niekoľkými etapami [1]. Prvé systémy boli založené na pravidlách, konkrétne na slovníkoch zakázaných slov a regulárnych výrazoch. Výhodou týchto systémov bola jednoduchosť a rýchlosť, avšak ich hlavným obmedzením bola nízka schopnosť prispôbiť sa novým formám toxicity. Tieto systémy bolo možné pomerne ľahko obísť zámernou úpravou slov alebo nahradením zakázaných výrazov ich opisnými ekvivalentmi.

Nasledujúca etapa priniesla klasické modely strojového učenia, ako sú Logistic Regression, SVM a Naive Bayes, pracujúce na základe TF-IDF reprezentácie textu [6]. Tieto modely sa učili rozpoznávať toxický obsah na základe štatistických vlastností slov a slovných spojení v tréovacích dátach. Dosiahli výrazne lepšie výsledky ako pravidlové systémy, no stále boli obmedzené v porozumení kontextu a významu textu, keďže každé slovo bolo spracúvané nezávisle bez ohľadu na jeho

okolie.

Ďalší významný posun nastal s príchodom neurónových sietí (CNN, RNN, LSTM), ktoré umožnili zohľadniť postupnosť slov a kontextové závislosti [6]. Rekurentné siete (RNN, LSTM) dokázali spracúvať text sekvenčne a zachytávať dlhodobé závislosti medzi slovami, čo výrazne zlepšilo schopnosť modelu porozumieť kontextu. Konvolučné siete (CNN) zase umožnili efektívne zachytávať lokálne vzory v texte. Napriek tomu tieto architektúry narážali na obmedzenia pri spracovaní dlhých textov a zachytávaní globálnych závislostí naprieč celou sekvenciou.

Prelomom sa stala transformerová architektúra [7] s mechanizmom self-attention, ktorý umožňuje modelu zachytávať vzťahy medzi tokenmi naprieč celým textom naraz. Vďaka predtréningu na rozsiahlych textových korpusoch modely ako BERT, RoBERTa a ich varianty nadobudli hlboké porozumenie jazyka, ktoré sa efektívne prenáša na špecifické úlohy ako detekcia toxicity prostredníctvom fine-tuningu [8]. Transformerové modely tak predstavujú súčasný štandard v úlohách detekcie online toxicity.

3.2 Hodnotiace metriky

Na hodnotenie kvality klasifikačných modelov sa používajú štandardné metriky, ktoré umožňujú objektívne porovnávanie výsledkov rôznych prístupov. Pri detekcii online toxicity je dôležité rozumieť nielen celkovej accuracy modelu, ale aj tomu, akým spôsobom model chybuje, či prehliada toxické komentáre alebo nesprávne blokuje netoxické.

3.2.1 Matica chýb

Matica chýb (confusion matrix) je tabuľka, ktorá zobrazuje rozdelenie predikcií modelu vzhľadom na skutočné označenia. Pri binárnej klasifikácii pozostáva zo štyroch hodnôt:

- **True Positive (TP)** — model správne označil komentár ako toxický.

- **True Negative (TN)** — model správne označil komentár ako netoxický.
- **False Positive (FP)** — model nesprávne označil netoxický komentár ako toxický.
- **False Negative (FN)** — model prehliadol toxický komentár a označil ho ako netoxický.

Tabuľka 3 – 1 Matica chýb pre binárnu klasifikáciu

Skutočná trieda	Predikovaná trieda	
	Toxický	Netoxický
Toxický	TP	FN
Netoxický	FP	TN

V kontexte detekcie online toxicity sú FN chyby obzvlášť nežiaduce, pretože znamenajú, že škodlivý obsah zostal neodhalený. FP chyby sú tiež dôležité, keďže znamenajú nesprávne zablokovanie legitímnych správ.

3.2.2 Accuracy, Precision, Recall a F1-score

Na základe matice chýb sa vypočítavajú základné metriky hodnotenia modelov.

Accuracy vyjadruje podiel správne klasifikovaných príkladov zo všetkých prípadov:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Pri výraznom nevyvážení tried môže byť accuracy zavádzajúca. Napríklad ak je 90 % komentárov netoxických, model, ktorý vždy predikuje „netoxický“, dosiahne accuracy 90 %, no neodhalí žiadny toxický komentár.

Precision vyjadruje podiel skutočne toxických komentárov spomedzi tých, ktoré model identifikoval ako toxické:

$$Precision = \frac{TP}{TP + FP}$$

Recall vyjadruje podiel odhalených toxických komentárov spomedzi všetkých skutočne toxických:

$$Recall = \frac{TP}{TP + FN}$$

F1-score je harmonický priemer Precision a Recall a používa sa vtedy, keď je dôležité zohľadniť oba ukazovatele súčasne:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

3.2.3 ROC-AUC

ROC krivka (Receiver Operating Characteristic) zobrazuje závislosť medzi podielom správne odhalených toxických komentárov (Recall) a podielom nesprávne označených netoxických komentárov (False Positive Rate) pri rôznych hodnotách klasifikačného prahu.

AUC (Area Under Curve) je plocha pod ROC krivkou. Nadobúda hodnoty od 0 do 1, pričom hodnota 1 zodpovedá ideálnej klasifikácii a hodnota 0,5 náhodnému odhadovaniu. ROC-AUC vyjadruje, do akej miery model dokáže rozlíšiť medzi dvoma triedami bez ohľadu na zvolený klasifikačný prah.

3.3 Klasické metódy textovej klasifikácie

Klasické metódy strojového učenia boli prvými prístupmi používanými na automatickú klasifikáciu textu. Napriek tomu, že moderné transformerové modely ich výrazne prekonávajú v accuracy, klasické metódy sa stále používajú ako baseline pri porovnávaní a v situáciách, kde sú výpočtové zdroje obmedzené.

3.3.1 TF-IDF vektorizácia

Pred odovzdaním textu klasifikátoru je potrebné ho previesť na číselný vektor. Jedným z najpoužívanejších spôsobov je TF-IDF (Term Frequency – Inverse Document

Frequency) [6].

TF-IDF priradí každému slovu váhu, ktorá vyjadruje, ako dôležité je dané slovo pre konkrétny dokument v porovnaní s celou kolekciou. Váha pozostáva z dvoch zložiek:

- **TF (Term Frequency)** — frekvencia slova v danom dokumente.
- **IDF (Inverse Document Frequency)** — inverzná frekvencia dokumentov obsahujúcich dané slovo. Čím vo väčšom počte dokumentov sa slovo vyskytuje, tým nižšie je jeho IDF. Tým sa znižuje váha často sa vyskytujúcich, no málo informatívnych slov, ako napríklad „a“, „the“ alebo „is“.

Slová, ktoré sa často vyskytujú v konkrétnom dokumente, ale zriedkavo v iných, dostávajú vysokú váhu. Práve tieto slová nesú najviac informácií o obsahu dokumentu. TF-IDF reprezentácia vytvára riedke vektory s vysokou dimenzionalitou, pričom väčšina hodnôt je nulová. Takáto reprezentácia je vhodná najmä pre lineárne klasifikátory, ktoré dokážu efektívne pracovať s veľkým počtom príznakov. V praxi sa pri TF-IDF okrem jednotlivých slov (unigramov) často používajú aj dvojice susedných slov (bigramy), čím sa zachytávajú aj krátke slovné spojenia, ktoré samostatné slová nedokážu reprezentovať.

3.3.2 Klasické klasifikátory a nevyváženosť tried

Logistic Regression je lineárny klasifikátor, ktorý pri binárnej klasifikácii odhaduje pravdepodobnosť, že vstup patrí do pozitívnej triedy. Pre každý vstup vypočíta váženú lineárnu kombináciu príznakov a výsledok prevedie sigmoidnou funkciou do intervalu $(0, 1)$, čo umožňuje interpretovať výstup ako pravdepodobnosť. Trénovanie prebieha minimalizáciou krížovej entropie a typicky sa kombinuje s L2 regularizáciou, ktorá penalizuje veľké hodnoty váh a obmedzuje riziko pretrénovania. Napriek svojej jednoduchosti dosahuje na TF-IDF reprezentáciách kvalitné výsledky a v textovej klasifikácii sa štandardne používa ako baseline.

Linear SVM (Support Vector Machine) hľadá hyperrovinu, ktorá oddeľuje triedy tak, aby okraj (margin) medzi hyperrovinou a najbližšími príkladmi oboch tried bol čo najväčší. Tieto najbližšie príklady sa nazývajú podporné vektory (support vectors) a sú jediné, ktoré priamo určujú polohu výslednej hranice. Keďže triedy v reálnych dátach často nie sú lineárne oddeliteľné, model súčasne minimalizuje počet chybné klasifikovaných príkladov. Kompromis medzi maximalizáciou okraja a toleranciou chýb sa riadi parametrom regularizácie. Lineárny variant SVM je hlavne vhodný pre riedke vysokorozmerné dáta, ako sú TF-IDF vektory.

Naive Bayes je pravdepodobnostný klasifikátor založený na Bayesovej vete. Predpokladá, že jednotlivé príznaky sú navzájom nezávislé, čo pri textových dátach nie je splnené, no v praxi to nebráni dosahovaniu dobrých výsledkov. Pre textovú klasifikáciu sa najčastejšie používa multinomická verzia (Multinomial Naive Bayes), ktorá pracuje s početnosťami výskytu slov v dokumentoch. Aby sa zabránilo nulovým pravdepodobnostiam pri slovách, ktoré sa v tréningových dátach v niektorej z tried nevyskytli, aplikuje sa aditívne vyhladzovanie. Hlavnou výhodou modelu je nízka výpočtová náročnosť pri tréningu aj inferencii.

Pri detekcii online toxicity je nevyváženosť tried typickým problémom, keďže toxické komentáre tvoria v reálnych dátach výraznú menšinu obsahu. Bez kompenzácie tejto nevyváženosti môže klasifikátor častejšie predikovať väčšinovú triedu. Riešenia sa delia do dvoch základných skupín: úpravy na úrovni dát (napríklad oversampling menšinovej triedy alebo undersampling väčšinovej) a úpravy na úrovni tréningu, pri ktorých sa chybám na menšinovej triede priraďuje v stratovej funkcii vyššia váha.

3.4 Transformerová architektúra

Transformerová architektúra predstavuje základ moderných modelov spracovania prirodzeného jazyka. Na rozdiel od starších prístupov, ako RNN alebo LSTM, ktoré spracúvajú text postupne slovo po slove, transformer dokáže spracovať celý vstup naraz. Umožňuje to mechanizmus self-attention, ktorý zachytáva vzťahy medzi všet-

kými slovami v texte.

3.4.1 Mechanizmus self-attention

Self-attention umožňuje modelu pre každé slovo určiť, ktoré iné slová v texte sú pre neho najdôležitejšie. Každý token sa transformuje do troch vektorov: Query (Q), Key (K) a Value (V). Váhy pozornosti sa vypočítajú ako skalárny súčin Q a K, vydelený hodnotou $\sqrt{d_k}$ (dimenzia vektora kľúča), a aplikovaný cez funkciu softmax [7]:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$


Výsledkom je reprezentácia každého tokenu, ktorá berie do úvahy celý kontext vstupu. Napríklad slovo „zámok“ dostane rôznu reprezentáciu vo vete „otvoril zámok na dverách“ a „navštívil stredoveký zámok“, pretože okolité slová sú iné.

V praxi sa používa **multi-head attention**, kde self-attention prebieha paralelne v niekoľkých hlavách [7]. Každá hlava sa môže zamerať na iný typ závislostí v texte. Výstupy všetkých hláv sa spoja a lineárne transformujú.

3.4.2 Architektúra encodera

Modely používané v tejto práci (BERT, RoBERTa, DistilBERT, ALBERT) sú založené na encoder časti transformera. Encoder pozostáva z niekoľkých identických vrstiev, pričom každá obsahuje:

- **Multi-head self-attention** — zachytáva vzťahy medzi tokenmi naprieč celým vstupom.
- **Feed-forward sieť** — dvojvrstvová plne prepojená sieť aplikovaná na každý token zvlášť.
- **Reziduálne spojenia a normalizácia vrstiev** — stabilizujú tréning a umožňujú trénovať hlbšie siete.



Obrázok 3 – 2 Architektúra jednej vrstvy encodera transformera

Každý token na vstupe dostane embedding tokenu a embedding pozície (informácia o umiestnení tokenu v sekvencii). Niektoré modely, ako napríklad BERT, používajú aj embedding segmentu (rozlišuje, ku ktorej vete token patrí). Výstupom encodera je sekvencia vektorov, jeden pre každý vstupný token.

3.4.3 Predtréning, fine-tuning a funkcia strát

Transformerové modely sa trénujú v dvoch fázach. **Predtréning** prebieha na veľkom množstve neoznačených textových dát, kde sa model učí všeobecné jazykové vzory. Vďaka predtréningu model sa nemusí učiť jazyk od nuly pri každej novej úlohe, čo výrazne znižuje množstvo potrebných označených dát. BERT bol trénovaný pomocou maskovaného jazykového modelovania (predikcia zakrytých tokenov) a predikcie nasledujúcej vety (Next Sentence Prediction, NSP) [9]. Táto druhá úloha bola v neskorších modeloch ako RoBERTa odstránená ako menej efektívna. **Fine-tuning** je fáza, kde sa predtrénovaný model doladí na konkrétnu úlohu pomocou

označených dát. V tejto práci bol fine-tuning vykonaný na úlohe binárnej klasifikácie toxicity. Nad výstupom encodera bola pridaná klasifikačná hlava, ktorej výstupy zodpovedajú dvom triedam: toxický a netoxický.

Funkcia strát použitá pri fine-tuningu bola krížová entropia (CrossEntropy-Loss), ktorá meria rozdiel medzi predikovanou pravdepodobnosťou a skutočnou triedou. Minimalizácia tejto funkcie počas tréningu vedie model k presnejším predikciám.

3.5 Prehľad použitých modelov

V tejto práci boli použité štyri transformerové modely, ktoré reprezentujú rôzne prístupy k architektúre a predtréningu. Každý z nich vychádza zo základnej encoder architektúry transformera, no líši sa spôsobom tréningu, veľkosťou alebo technikou kompresie.

3.5.1 BERT

BERT (Bidirectional Encoder Representations from Transformers) bol predstavený tímom Google v roku 2018 [9]. Na rozdiel od predchádzajúcich modelov, ktoré spracúvajú text jednosmerne, BERT číta text obojsmerne, čo mu umožňuje lepšie porozumieť kontextu každého slova.

Model bol predtrénovaný na textoch z Wikipédie a knižného korpusu (celkovo približne 16 GB textu) pomocou maskovaného jazykového modelovania a predikcie nasledujúcej vety (NSP). V tejto práci bol použitý variant **bert-base-uncased**, ktorý obsahuje 12 vrstiev, 12 hláv mechanizmu pozornosti a 110 miliónov parametrov. Variant *uncased* prevádza vstupný text na malé písmená pred tokenizáciou, čo znamená, že model nerozlišuje medzi veľkými a malými písmenami. BERT slúžil ako základný referenčný model, voči ktorému sa porovnávali ostatné architektúry.

3.5.2 RoBERTa

RoBERTa (Robustly Optimized BERT Pretraining Approach) vznikla v roku 2019 vo Facebook AI ako vylepšenie pôvodného BERT-u [10]. Architektúra zostala rovnaká s 12 vrstvami a 12 hlavami mechanizmu pozornosti, no väčší slovník tokenizátora zvýšil celkový počet parametrov na 125 miliónov. Predtréning bol výrazne zmenený: model bol trénovaný na výrazne väčšom korpuse dát ako BERT (160 GB oproti 16 GB), dlhší čas a bez úlohy NSP, ktorá sa ukázala ako menej efektívna. Navyše bolo použité dynamické maskovanie, kde sa masky menia pri každom prechode cez tréningové dáta.

V tejto práci bol použitý variant **roberta-base**. RoBERTa bola zvolená s cieľom overenia, či kvalitnejší predtréning prináša lepšie výsledky pri detekcii toxicity v porovnaní s pôvodným BERT-om.

3.5.3 DistilBERT

DistilBERT bol predstavený tímom Hugging Face v roku 2019 ako kompaktnejšia verzia BERT-u [11]. Na jeho vytvorenie bola použitá technika knowledge distillation, pri ktorej sa menší model (študent) učí napodobňovať správanie väčšieho modelu (učiteľ). Výsledkom je model so 6 vrstvami, 12 hlavami mechanizmu pozornosti a 67 miliónmi parametrov, ktorý je o 39 % menší ako BERT, optimalizovaný na rýchlejšiu inferenciu a podľa pôvodnej publikácie zachováva až 97 % jeho výkonnosti.

V tejto práci bol použitý variant **distilbert-base-uncased**. DistilBERT bol vybraný ako reprezentant kompaktných modelov s akcentom na rýchlosť inferencie a nízke nároky na pamäť.

3.5.4 ALBERT

ALBERT (A Lite BERT) bol predstavený v roku 2019 ako alternatívny prístup ku kompresii transformerových modelov [12]. Na rozdiel od DistilBERT, ktorý redukuje

počet vrstiev, ALBERT zachováva 12 vrstiev, no používa dve techniky znižovania počtu parametrov:

- **Zdieľanie parametrov medzi vrstvami** — všetky vrstvy encodera zdieľajú rovnaké váhy. Na rozdiel od BERT-u, kde každá vrstva má vlastné parametre, ALBERT používa jednu sadu váh opakovane, čo výrazne znižuje počet parametrov bez zníženia hĺbky siete.
- **Faktorizácia embedding matice** — embedding matica je rozložená na dve menšie matice. Tým sa oddelí veľkosť slovníka od veľkosti skrytých vrstiev, čo znižuje celkový počet parametrov.

V tejto práci bol použitý variant `albert-base-v2`, ktorý má 12 vrstiev, no iba 11,7 milióna parametrov, čo je približne 10-krát menej ako BERT. Napriek výraznému zníženiu počtu parametrov však ALBERT nevykazuje rýchlejšiu inferenciu ako BERT, pretože počet výpočtových operácií zostáva rovnaký. Zdieľanie parametrov znižuje pamäťové nároky, nie výpočtovú náročnosť. Tento jav bol potvrdený aj v experimentálnej časti tejto práce.

Tabuľka 3 – 2 Porovnanie použitých transformerových modelov

Model	Vrstvy	Hlavy	Parametre	Kompresia
BERT	12	12	110M	žiadna
RoBERTa	12	12	125M	žiadna
DistilBERT	6	12	67M	knowledge distillation
ALBERT	12	12	11,7M	zdieľanie parametrov

Tieto modely boli zvolené tak, aby pokrývali spektrum od plne parametrizovaného modelu (BERT), cez optimalizované predtréninové prístupy (RoBERTa), až po efektívne komprimované architektúry (DistilBERT a ALBERT).

3.6 Súvisiace práce

Výskum v oblasti detekcie toxicity v online prostredí prešiel výrazným vývojom, od klasických metód strojového učenia až po moderné transformerové architektúry.

Fan a kol. [8] aplikovali modely na základe BERT na klasifikáciu toxických komentárov, pričom ich doladili na datasete Jigsaw Toxic Comment Classification Challenge. Model BERT-base dosiahol hodnotu ROC-AUC 0,9856 na verejnej a 0,9860 na súkromnej testovacej množine súťaže Kaggle. Autori tiež porovnali BERT s tromi ďalšími modelmi: Multilingual BERT (0,9852), DistilBERT (0,9848) a RoBERTa (0,9772). Doladený model bol následne použitý na analýzu toxicity v tweetoch súvisiacich s témou Brexitu. Práca potvrdzuje, že modely trénované na datasete Jigsaw sú aplikovateľné aj na iné domény, čo priamo súvisí s krížovým testovaním vykonaným v tejto práci.

Sundelin [13] porovnal tri transformerové modely, RoBERTa, ALBERT a DistilBERT, na identifikáciu toxického jazyka v online prostredí. Modely boli doladené na kombinovanom datasete z ôsmich zdrojov (36 535 toxických a 23 151 netoxických príkladov). Na testovacích dátach dosiahla RoBERTa najlepší F1-score 88,53 % a accuracy 88,92 %, nasledoval ALBERT s F1-score 87,43 % a DistilBERT s F1-score 86,07 %. Pri hodnotení na reálnych dátach z Redditu s prahom istoty 80 % vykazoval DistilBERT najvyváženejší pomer kvality a rýchlosti: čas tréovania bol len 36 minút oproti 56 minútam pri modeli RoBERTa a 2 hodinám 15 minútam pri modeli ALBERT. Táto práca je obzvlášť relevantná, keďže skúma rovnaké tri modely ako naša práca a potvrdzuje, že DistilBERT predstavuje najlepší kompromis medzi kvalitou a rýchlosťou.

Guillaume a kol. [14] porovnali niekoľko transformerových modelov, HateBERT, RoBERTa a BERTweet, na datasete Jibes&Delight obsahujúcom komentáre z Redditu. Najlepší výsledok dosiahol model RoBERTa st4-aug trénovaný s augmentáciou dát: ROC-AUC 0,9955 a F1-score 0,9673, čím prekonal HateBERT s F1-score 0,9519 aj BERTweet s F1-score 0,9603. Autori tiež poukazujú na to, že zložitosť modelu nie je určujúcim faktorom kvality. Menší model s lepším extrahovaním príznakov a augmentáciou dát prekonal väčšie alternatívy. Výsledky tejto práce potvrdzujú, že augmentácia dát a kvalita predtrénovacieho korpusu môžu výrazne ovplyvniť výkonnosť modelu.

Duchêne a kol. [15] vykonali rozsiahlu porovnávaciu štúdiu modelov na datasete Civil Comments obsahujúcom 1,8 milióna komentárov s viacnásobnými anotáciami (toxicita, obscénosť, útok na identitu, urážka, hrozba a sexuálny obsah). Porovnávané boli transformerové architektúry (BERT, ALBERT, DistilBERT, HateBERT, RoBERTa s rôznymi stratovými funkciami, XLM-RoBERTa, BERTweet, XLNet), rekurentné siete (BiGRU, BiLSTM), konvolučné siete (ResNet44, ResNet56) a Compact Convolutional Transformer (CCT). Najvyššiu hodnotu Macro ROC-AUC dosiahol model RoBERTa s Focal Loss (alternatívna stratová funkcia optimalizovaná pre nevyvážené datasety) s hodnotou 0,9818, pričom všetky varianty BERT dosiahli porovnateľné výsledky bez ohľadu na veľkosť alebo optimalizáciu. Rekurentné siete (BiLSTM, BiGRU) boli 5- až 8-krát rýchlejšie pri inferencii než modely BERT pri len mierne nižšej hodnote ROC-AUC (0,9754 a 0,9748). DistilBERT predstavoval najlepší kompromis medzi výkonom a rýchlosťou inferencie spomedzi transformerových modelov. Štúdia tiež hodnotila zaujatosť modelov voči identitným skupinám: konvolučné modely a CCT vykazovali vyššiu asociačnú zaujatosť než BERT, RNN a XLNet. Táto práca je relevantná pre náš výskum, keďže priamo porovnáva transformerové architektúry vrátane DistilBERT a RoBERTa za rovnakých tréningových podmienok a hodnotí nielen výkon, ale aj zaujatosť a čas inferencie.

Bonetti a kol. [6] porovnali klasické metódy strojového učenia a hlboké učenie pre detekciu toxických komentárov na sociálnych sieťach. Dataset bol zostavený zlúčením deviatich verejne dostupných anotovaných datasetov tweetov, čím vznikol súbor 111 131 jedinečných anglických tweetov (57,43 % neutrálnych a 42,57 % toxických). Testované boli modely logistickej regresie, Random Forest, SVM v kombinácii s LSA a LDA a transformerový model BERTweet. BERTweet dosiahol najvyšší F1-score 91,40 % a ROC-AUC 0,9248, avšak klasické modely sa priblížili na porovnateľnú úroveň: LR dosiahla F1-score 90,73 %, SVM+LSA 91,12 % a RF 90,11 %. Kľúčovým zistením bol výrazný rozdiel v čase inferencie: LR spracovala jeden tweet za 14 μ s, kým BERTweet potreboval 5 754 μ s, teda viac ako 400-krát dlhšie. Autori uzatvárajú, že výkonnostný rozdiel medzi transformerom a klasickými modelmi je

príliš malý na to, aby odôvodnil jeho výrazne vyššie výpočtové nároky. Táto štúdia je relevantná pre náš výskum, keďže poukazuje na dôležitosť hodnotenia nielen accuracy, ale aj praktickej použiteľnosti modelov.

Abusaqer a kol. [16] porovnali 38 konfigurácií modelov pre detekciu nenávistných prejavov na viacerých datasetoch s rozsahom od 6 500 do 451 000 vzoriek. Porovnávané boli transformerové architektúry (BERT, RoBERTa, DistilBERT), hlboké neurónové siete (CNN, LSTM, GRU, Hierarchical Attention Networks) a klasické metódy strojového učenia (SVM, CatBoost, Random Forest). Na kombinovanom datasete strednej veľkosti (48 049 vzoriek) dosiahla RoBERTa hodnotu accuracy 91,48 % a F1-score 92,62 %, čo predstavovalo najlepší výsledok spomedzi všetkých testovaných architektúr. Spomedzi klasických metód dosiahol CatBoost F1-score 89,60 % a SVM F1-score 89,50 %, avšak pri výrazne nižšej výpočtovej náročnosti. Autori tiež zistili, že vyvážené datasety strednej veľkosti dosahujú vyšší výkon ako väčšie nevyvážené datasety, pričom RoBERTa na vyváženej množine 267 000 vzoriek dosiahla hodnotu accuracy 91,89 % a F1-score 91,89 %. Výsledky tejto štúdie ukazujú, že transformerové architektúry vo všeobecnosti prekonávajú klasické metódy, a zároveň poukazujú na dôležitosť charakteristík tréningových dát, čo je priamo relevantné pre interpretáciu výsledkov dosiahnutých v tejto práci.

Aklouche a kol. [17] porovnali sedem transformerových modelov: BERT, RoBERTa, DistilBERT, ALBERT, XLM-RoBERTa, ELECTRA a Large-BERT na datasete Davidson obsahujúcom 25 296 tweetov s tromi triedami: nenávistný jazyk (5,70 %), urážlivý jazyk (77,60 %) a neutrálny obsah (16,70 %). Každý model bol doladený s rôznymi kombináciami hyperparametrov. Spomedzi jednotlivých modelov dosiahol DistilBERT najlepšie výsledky s hodnotou accuracy 92,17 % a F1-score 91,53 %. Nasledoval Large-BERT s accuracy 91,95 % a F1-score 91,00 % a BERT s accuracy 91,82 % a F1-score 91,22 %. RoBERTa dosiahla F1-score 90,74 % a ALBERT F1-score 90,55 %. Autori následne aplikovali šesť stratégií ansamblového učenia (techník kombinovania predikcií viacerých modelov za účelom zlepšenia celkového výkonu), pričom metóda stacking (kombinácia predikcií modelov pomocou

finálneho meta-klasifikátora) dosiahla najlepší výsledok s hodnotou accuracy 92,47 % a F1-score 91,80 %, čím prekonala všetky individuálne modely aj referenčné metódy z literatúry. Štúdia potvrdzuje, že DistilBERT môže dosahovať porovnateľné alebo lepšie výsledky ako väčšie modely pri nižšej výpočtovej náročnosti, čo podporuje záver o efektívnosti kompaktnejších transformerových architektúr dosiahnutý aj v tejto práci.

Iftikhar a kol. [18] navrhli hybridný prístup kombinujúci predtrénovaný model RoBERTa-Large s klasifikátorom XGBoost pre detekciu nenávistných prejavov a urážlivého jazyka na sociálnych sieťach. Experimenty boli vykonané na troch verejne dostupných datasetoch: ToxicTweets (56 744), Davidson (25 296) a HateSpeechDetection (3 001). Navrhovaný model dosiahol na Davidsonovom datasete accuracy 92,42 %, precision 91,03 %, recall 92,33 % a F1-score 91,24 %. Na datasete ToxicTweets dosiahol accuracy aj F1-score 95 % a na datasete HateSpeechDetection accuracy 97 % a F1-score 96 %. Ako baseline modely autori použili výsledky z existujúcej literatúry na Davidsonovom datasete: ELECTRA dosiahol F1-score 91 %, ALBERT 90 %, DistilBERT 75 % a RoBERTa 74 %. Zistenia autorov naznačujú, že kombinácia transformerových reprezentácií s klasickými klasifikátormi môže ďalej zlepšiť výsledky oproti samotnému doladeniu transformera, čo je relevantné pri hodnotení prístupu použitého v tejto práci.

Lashkarashvili a Tsintsadze [19] skúmali detekciu toxicity v online diskusiách v gruzínskom jazyku. Bol zostavený dataset z 10 000 komentárov z gruzínskeho fóra a natrénovaných bolo niekoľko architektúr: NCP, BiRNN, CNN, BiGRU-CNN, BiLSTM, BiGRU a Transformer-encoder. Najlepší výsledok dosiahla CNN s accuracy 0,888 a ROC-AUC 0,942. Autori poznamenávajú, že transformerový model dosiahol nižší výkon než CNN architektúry, pravdepodobne kvôli relatívne malému objemu tréovacích dát (10 000 príkladov). Táto práca ukazuje obmedzenia transformerových modelov pri malom objeme tréovacích dát, čo je relevantné pri interpretácii výsledkov dosiahnutých v tejto bakalárskej práci.

Antypas a Camacho-Collados [20] analyzovali schopnosť modelov detekcie ne-

návistných prejavov fungovať na datasetoch odlišných od tréningových dát. Zostavili unifikovaný dataset z 13 existujúcich datasetov tweetov (celkovo 83 230 príspevkov) a doladili štyri jazykové modely: BERT-base, RoBERTa-base, BERTweet a TimeLMs-21 na každom datasete zvlášť aj na kombinovanom datasete. Modely tréňované na kombinovanom datasete vo väčšine prípadov prekonali modely tréňované na jednotlivých datasetoch: TimeLMs dosiahol priemerný F1-score 70,7 % naprieč všetkými testovacími datasetmi, BERTweet 70,1 %, RoBERTa 69,7 % a BERT 67,9 %, v porovnaní s hodnotami 61,0 %, 70,1 %, 60,1 % a 57,2 % pri tréňovaní na najlepšom jednotlivom datasete. Autori tiež ukázali, že modely tréňované na jednom datasete výrazne strácajú na výkone pri testovaní na iných datasetoch. Napríklad model tréňovaný na datasete CMS dosiahol F1-score 87 % na vlastných testovacích dátach, avšak len 52 % na datasete AYR. Pre túto prácu je dôležité najmä to, že výsledky potvrdzujú výrazný pokles výkonu pri krížovom testovaní na doménach odlišných od tréningových dát, čo priamo korešponduje s pozorovaným poklesom výkonu pri testovaní na externých datasetoch Civil Comments a TweetEval.

Analýza súvisiacich prác ukazuje, že transformerové modely vo väčšine prípadov prekonávajú klasické metódy strojového učenia pri detekcii toxicity, avšak nie vždy je tento rozdiel výrazný. Pri malom objeme tréningových dát môžu jednoduchšie architektúry ako CNN dosahovať porovnateľné výsledky, a výpočtová náročnosť transformerov môže prevyšovať ich prínosy v praxi. Viaceré práce tiež poukazujú na výrazný pokles výkonu modelov pri testovaní na doménach odlišných od tréningových dát, čo zdôrazňuje význam krížového testovania. Systematické porovnanie štyroch transformerových architektúr v rámci jedného experimentu s následným krížovým testovaním na externých doménach zostáva aktuálnou úlohou, ktorej sa venuje táto práca.

4 Experimenty a analýza výsledkov

4.1 Cieľ experimentálnej časti

Cieľom experimentálnej časti bolo overiť efektívnosť transformerových modelov pri detekcii toxických komentárov v online prostredí.

Na tento účel boli vykonané nasledujúce kroky:

1. Výber a predspracovanie datasetu Jigsaw Toxic Comment Classification Challenge.
2. Trénovanie štyroch transformerových modelov: BERT, RoBERTa, DistilBERT, ALBERT.
3. Trénovanie troch klasických baseline modelov na porovnanie: Logistic Regression, Linear SVM a Naive Bayes.
4. Hodnotenie a porovnanie všetkých modelov podľa štandardných metrík.
5. Testovanie trénovaných modelov na iných datasetoch: Civil Comments a TweetEval Offensive.
6. Manuálna analýza chýb (FN/FP) modelu BERT a identifikácia systémových slabín.

4.2 Dataset Jigsaw a predspracovanie dát

Na tréovanie a hodnotenie modelov bol zvolený dataset Jigsaw Toxic Comment Classification Challenge, publikovaný na platforme Kaggle organizáciou Jigsaw v spolupráci s Google [21]. Dataset obsahuje komentáre z diskusných stránok Wikipédie, ktoré boli ručne anotované do šiestich kategórií toxicity: *toxic*, *severe_toxic*, *obscene*, *threat*, *insult* a *identity_hate*. Celkovo dataset obsahuje viac ako 159 000

komentárov. Tento výber je motivovaný tým, že dataset patrí medzi najčastejšie používané vo výskume zameranom na detekciu toxického obsahu v sociálnych sieťach, čo umožňuje porovnať získané výsledky s inými prácami v tejto oblasti.

Keďže hlavnou úlohou bolo klasifikovať toxicitu komentárov, a nie typ toxicity, z viactriednej anotácie bola vytvorená jednotná binárna značka: komentár sa považuje za toxický (1), ak je označený aspoň v jednej zo šiestich kategórií, v opačnom prípade je netoxický (0). V dôsledku toho dataset obsahuje 16 225 toxických príkladov (10,2 %) a 143 346 netoxických (89,8 %). Táto výrazná nerovnováha medzi triedami je typická pre reálne platformy, kde toxické príspevky tvoria menšinu obsahu.

Dáta boli rozdelené na trénovaciu a validačnú množinu v pomere 90:10 s použitím stratifikovaného výberu (stratified sampling). Vo všetkých experimentoch sa použilo pevné náhodné seed rovné 42, čo zabezpečuje identickú validačnú vzorku pre všetky modely a umožňuje priamo porovnávať ich výsledky. Konečné rozdelenie bolo 143 613 trénovacích a 15 958 validačných príkladov.

Dodatočné predspracovanie textu sa nevykonávalo, pretože transformerové modely majú vlastný zabudovaný tokenizátor, ktorý spracováva surový text priamo. Pre klasické baseline modely sa premena textu na numerické vektory vykonávala prostredníctvom TF-IDF vektorizácie vo fáze trénovania.

4.3 Trénovanie transformerových modelov

4.3.1 Spoločná konfigurácia tréningu

Všetky štyri transformerové modely boli trénované formou fine-tuningu s identickými hyperparametrami. Predtrénované váhy modelov boli počas fine-tuningu aktualizované na úlohe binárnej klasifikácie toxicity. Týmto spôsobom je zabezpečené objektívne porovnanie architektúr, keďže rozdiely vo výsledkoch vyplývajú prevažne z vlastností samotných modelov, a nie z rozdielov v nastaveniach trénovania. Hyperparametre boli vybrané na základe odporúčaní z pôvodného článku o modeli BERT [9]. Na implementáciu a trénovanie transformerových modelov bola použitá

knižnica Hugging Face Transformers v kombinácii s frameworkom PyTorch. Po analýze datasetu bolo rozhodnuté, že maximálna dĺžka textu je 256 tokenov, čo pokrýva 93,1 % všetkých údajov. Preto sa nepoužila dĺžka 512 tokenov, ktorá by zvýšila pokrytie na 97,8 %, ale zároveň by približne zdvojnásobila čas tréovania.

Ako optimalizátor bol použitý AdamW s rozdelením parametrov do dvoch skupín: na váhy bol aplikovaný weight decay rovný 0,01, zatiaľ čo na parametre bias a LayerNorm nebol weight decay aplikovaný, čo umožňuje predísť nežiaducej regularizácii týchto parametrov. Počas tréovania nebola hodnota learning rate konštantná: v prvých 10 % krokov sa postupne zvyšovala (warmup) a potom sa plynule lineárne znižovala až na nulu. Použilo sa tiež obmedzenie normy gradientov (gradient clipping) s maximálnou hodnotou 1,0, čo zabránilo explozívnomu rastu gradientov. Ako stratová funkcia bola použitá krížová entropia (CrossEntropyLoss) pre binárnu klasifikáciu. Na rozdiel od baseline modelov nebol pri tréovaní transformerových modelov použitý vyvažovač tried. Tento prístup zodpovedá štandardnej praxi fine-tuningu transformerových modelov používanej v súvisiacich prácach [8, 13, 20], kde sa class weighting bežne nepoužíva.

Po každej epoche sa vypočítali metriky na validačnej vzorke. Bola vybraná verzia modelu s najlepšou hodnotou F1-score, práve tá sa použila na konečné hodnotenie, pretože kvôli pretrénovaniu sa najlepší výsledok nedosiahol vždy v poslednej epoche.

Všetky experimenty sa vykonávali na GPU NVIDIA GeForce RTX 5070 s 12 GB pamäte. Po tréovaní modelu BERT s fp32 bolo prijaté rozhodnutie, že na urýchlenie procesu tréovania modelov RoBERTa, DistilBERT a ALBERT sa dodatočne použije technológia Automatic Mixed Precision, ktorá umožňuje vykonávať väčšinu výpočtov s 16-bitovou presnosťou, čo prinieslo približne dvojnásobné zrýchlenie tréovania bez významného vplyvu na kvalitu modelu. Každý model bol tréovaný v jedinom behu. Pri opakovanom tréovaní s iným inicializačným seed môžu hodnoty F1-score minimálne kolísať, čo by nemalo vplyv na poradie modelov ani na hlavné závery porovnania.

Tabuľka 4 – 1 Spoločné hyperparametre tréovania transformerových modelov

Parameter	Hodnota
Maximálna dĺžka sekvencie	256 tokenov
Veľkosť batchu	16
Počet epoch	3
Learning rate	2×10^{-5}
Warmup ratio	10 %
Weight decay	0,01
Optimalizátor	AdamW
Plánovač learning rate	Lineárny s warmupom
Gradient clipping	max_norm = 1,0

4.3.2 BERT-base-uncased

Ako základný referenčný model bol zvolený model BERT. Bol načítaný z knižnice Hugging Face vo verzii `bert-base-uncased`. Rýchlosť dosahovala približne 5,82 iterácie za sekundu a celkový čas troch epoch bol približne 77 minút.

Tabuľka 4 – 2 Priebeh tréovania modelu BERT podľa epoch

Epocha	Train Loss	Train F1	Val Loss	Val F1	Val ROC-AUC
1	0,1226	0,7818	0,1018	0,8276	0,9856
2	0,0711	0,8909	0,1210	0,8427	0,9864
3	0,0379	0,9506	0,1563	0,8387	0,9856

Už v prvej epoche dosiahol model dobrý výsledok Val F1 0,8276, čo naznačuje, že predtrénované váhy modelu BERT sú dobre prenositeľné na úlohu detekcie toxicity. V druhej epoche sa kvalita zlepšila na maximálnu hodnotu Val F1 0,8427 pri súčasnom poklese Train Loss na 0,0711. V tretej epoche Train F1 pokračoval v raste až na 0,9506, avšak Val F1 klesol na 0,8387 a Val Loss vzrástol z 0,1210 na 0,1563. Rozdiel medzi Train F1 (0,9506) a Val F1 (0,8387) v tretej epoche dosahuje 0,1119, čo je výrazný príznak pretrénovania. Z tohto dôvodu bol ako finálny zachovaný model z druhej epochy. Vysoká hodnota Val ROC-AUC 0,9864 pri súčasne nižšom F1-score 0,8427 odráža ťažkosti klasifikátora pri nevyvážených triedach s pevným prahom 0,5.

Tabuľka 4 – 3 Finálne metriky modelu BERT na validačnej množine

Metrika	Hodnota
Accuracy	0,9683
F1-score	0,8427
ROC-AUC	0,9864
Precision (pre triedu „toxický“)	0,85
Recall (pre triedu „toxický“)	0,83
TN (True Negative)	14 097
FP (False Positive)	238
FN (False Negative)	268
TP (True Positive)	1 355

4.3.3 RoBERTa-base

Model RoBERTa bol zvolený ako model s vylepšeným predtréninom oproti modelu BERT. Bol načítaný z knižnice Hugging Face vo verzii **roberta-base**. Rýchlosť dosahovala približne 11,4 iterácie za sekundu, celkový čas troch epoch bol približne 40 minút.

Tabuľka 4 – 4 Priebeh tréningu modelu RoBERTa podľa epoch

Epocha	Train Loss	Train F1	Val Loss	Val F1	Val ROC-AUC
1	0,1303	0,7908	0,1140	0,8288	0,9853
2	0,0848	0,8784	0,1177	0,8341	0,9863
3	0,0578	0,9234	0,1480	0,8370	0,9862

V prvej epoche model dosiahol Val F1 0,8288, čo je mierne vyššia hodnota ako pri modeli BERT v rovnakej epoche (0,8276). Na rozdiel od modelu BERT, kde bol najlepší výsledok dosiahnutý v druhej epoche, RoBERTa vykazovala postupné zlepšovanie Val F1 vo všetkých troch epochách (0,8288 → 0,8341 → 0,8370), hoci Val Loss v tretej epoche vzrástol z 0,1177 na 0,1480. Celkové zlepšenie Val F1 od prvej do tretej epochy bolo 0,0082, čo je výrazne menej ako pri modeli BERT medzi jeho prvou a druhou epochou (0,0151). Keďže najvyššia hodnota Val F1 bola dosiahnutá v tretej epoche, ako finálny bol zachovaný model z tretej epochy (Val F1 0,8370).

Pomalší nárast Val Loss v porovnaní s modelom BERT naznačuje, že RoBERTa je menej citlivá na pretrénovanie pri tomto počte epoch.

Tabuľka 4 – 5 Finálne metriky modelu RoBERTa na validačnej množine

Metrika	Hodnota
Accuracy	0,9667
F1-score	0,8370
ROC-AUC	0,9862
Precision (pre triedu „toxický“)	0,83
Recall (pre triedu „toxický“)	0,84
TN (True Negative)	14 064
FP (False Positive)	271
FN (False Negative)	260
TP (True Positive)	1 363

4.3.4 DistilBERT

Model DistilBERT bol zvolený ako odľahčená verzia modelu BERT získaná metódou knowledge distillation. Bol načítaný z knižnice Hugging Face vo verzii `distilbert-base-uncased`. Rýchlosť dosahovala približne 21,4 iterácie za sekundu, celkový čas troch epoch bol približne 22 minút.

Tabuľka 4 – 6 Priebeh tréovania modelu DistilBERT podľa epoch

Epocha	Train Loss	Train F1	Val Loss	Val F1	Val ROC-AUC
1	0,1197	0,7929	0,1034	0,8303	0,9848
2	0,0692	0,8885	0,1102	0,8309	0,9862
3	0,0398	0,9446	0,1539	0,8327	0,9841

V prvej epoche model dosiahol Val F1 0,8303. Na rozdiel od modelov BERT a RoBERTa, DistilBERT vykazoval výrazne stabilnejší priebeh tréovania: Val F1 sa medzi epochami menil len minimálne ($0,8303 \rightarrow 0,8309 \rightarrow 0,8327$), pričom celkové zlepšenie za tri epochy predstavovalo len 0,0024. Pritom Val Loss rástol vo všetkých epochách ($0,1034 \rightarrow 0,1102 \rightarrow 0,1539$) a Val ROC-AUC v tretej epoche klesol na 0,9841 oproti hodnote 0,9862 v druhej epoche, čo naznačuje, že model dosiahol stabilný stav už po prvej epoche a ďalšie epochy neprinášali výrazné zlepšenie.

Keďže rozdiel Val F1 medzi epochami bol zanedbateľný, výber finálnej epochy mal minimálny vplyv na výsledok. Napriek tomu bol podľa jednotného kritéria výberu zachovaný model s najvyššou hodnotou Val F1, teda model z tretej epochy (Val F1 0,8327). Hoci DistilBERT má o 39 % menej parametrov ako BERT (67M oproti 110M), dosiahol 98,8 % jeho kvality, čo potvrdzuje efektívnosť metódy knowledge distillation.

Tabuľka 4 – 7 Finálne metriky modelu DistilBERT na validačnej množine

Metrika	Hodnota
Accuracy	0,9663
F1-score	0,8327
ROC-AUC	0,9841
Precision (pre triedu „toxický“)	0,84
Recall (pre triedu „toxický“)	0,82
TN (True Negative)	14 085
FP (False Positive)	250
FN (False Negative)	287
TP (True Positive)	1 336

4.3.5 ALBERT-base-v2

Model ALBERT bol zvolený ako model s alternatívnym prístupom ku kompresii prostredníctvom zdieľania parametrov medzi vrstvami. Bol načítaný z knižnice Hugging Face vo verzii `albert-base-v2`. Rýchlosť dosahovala približne 9,4 iterácie za sekundu, celkový čas troch epoch bol približne 50 minút.

Tabuľka 4 – 8 Priebeh tréningu modelu ALBERT podľa epoch

Epocha	Train Loss	Train F1	Val Loss	Val F1	Val ROC-AUC
1	0,1513	0,7703	0,1314	0,8089	0,9809
2	0,1110	0,8420	0,1293	0,8190	0,9838
3	0,0910	0,8797	0,1380	0,8288	0,9842

Model ALBERT vykazoval najpomalšiu konvergenciu spomedzi všetkých testovaných transformerových modelov. V prvej epoche dosiahol Val F1 0,8089, čo je

o 0,0187 menej ako BERT v rovnakej epoche. Val F1 sa zlepšoval vo všetkých epochách ($0,8089 \rightarrow 0,8190 \rightarrow 0,8288$), avšak absolútne hodnoty Val F1 zostávali najnižšie spomedzi všetkých testovaných transformerových modelov v každej epoche. Train F1 v tretej epoche dosiahol len 0,8797 v porovnaní s hodnotou 0,9506 pri modeli BERT, čo je ďalším znakom pomalšieho učenia tejto architektúry. Val Loss klesal od prvej do druhej epochy ($0,1314 \rightarrow 0,1293$) len minimálne a v tretej epoche opäť mierne vzrástol na 0,1380. Keďže najvyššia hodnota Val F1 bola dosiahnutá v tretej epoche, ako finálny bol zachovaný model z tretej epochy (Val F1 0,8288). Napriek výrazne menšiemu počtu parametrov (11,7M oproti 110M pri modeli BERT) bola rýchlosť inferencie modelu ALBERT (7,42 ms) pomalšia ako pri modeli BERT (6,78 ms), čo potvrdzuje, že zdieľanie parametrov medzi vrstvami znižuje pamäťové nároky, no nie výpočtovú náročnosť samotnej inferencie.


Tabuľka 4–9 Finálne metriky modelu ALBERT na validačnej množine

Metrika	Hodnota
Accuracy	0,9658
F1-score	0,8288
ROC-AUC	0,9842
Precision (pre triedu „toxický“)	0,84
Recall (pre triedu „toxický“)	0,81
TN (True Negative)	14 090
FP (False Positive)	245
FN (False Negative)	301
TP (True Positive)	1 322

4.3.6 Porovnanie priebehu tréovania

Obrázok 4–1 sumarizuje priebeh tréovania všetkých štyroch transformerových modelov. Horný rad zobrazuje vývoj F1-score a dolný rad vývoj Loss, v oboch prípadoch na tréovacej aj validačnej množine. Vo všetkých štyroch prípadoch Train F1 plynule rastie, zatiaľ čo Val F1 rastie výrazne pomalšie. Najzreteľnejšie sa pretrénovanie prejavuje na priebehu Loss: Train Loss monotónne klesá, zatiaľ čo Val Loss rastie, čím vzniká charakteristické rozbíhanie oboch kriviek. Najvýraznejšie je toto rozbíhanie

pri modeli BERT, kde Val F1 dosahuje maximum v druhej epoche a následne klesá, čo zdôvodňuje výber modelu z druhej epochy ako finálneho. RoBERTa vykazuje miernejší nárast Val Loss než BERT, čo naznačuje jej nižšiu citlivosť na pretrénovanie pri tomto počte epoch. Obrázok vizuálne potvrdzuje rozhodnutie opísané v časti 4.3.1, teda vyberať model podľa najvyššej hodnoty Val F1, a nie z poslednej epochy.



Obrázok 4–1 Pribeh tréovania transformerových modelov: F1-score (hore) a Loss (dole) na tréovacej a validačnej množine počas troch epoch

4.4 Baseline models

Na porovnanie efektivity transformerových modelov boli natréované tri klasické baseline modely na rovnakých dátach s identickým rozdelením tréovacej a validačnej množiny (`seed = 42`). Boli zvolené tri modely reprezentujúce rôzne prístupy k textovej klasifikácii: Logistic Regression ako lineárny klasifikátor, Linear SVM ako klasifikátor založený na podporných vektoroch a Naive Bayes ako pravdepodobnostný klasifikátor. Na rozdiel od transformerových modelov tieto modely nevyžadovali GPU a celé tréovanie prebiehalo výlučne na CPU.

Pred tréovaním bol text prevedený na číselné reprezentácie pomocou TF-IDF vektorizácie. Použité boli unigramy a bigramy, slovník obsahoval 50 000 najčastejších tokenov, minimálna frekvencia slova bola nastavená na `min_df = 2`, maximálna na `max_df = 0,95`, bola použitá sublineárna normalizácia frekvencie a normalizácia

diakritiky (`strip_accents = „unicode“`). Vektorizátor bol natrénovaný iba na trénovacej množine a následne aplikovaný na validačnú množinu bez ďalšieho doučenia.

Model Logistic Regression bol trénovaný s L2 regularizáciou ($C = 4,0$) a parametrom `class_weight = balanced` na kompenzáciu nevyváženosti tried. Hodnota $C = 4,0$ bola zvolená na základe experimentálneho overovania na validačnej množine, pričom vyššia hodnota C znamená slabšiu regularizáciu, čo sa ukázalo výhodným pri TF-IDF reprezentáciách s vysokým počtom príznakov (50 000). Čas tréovania bol približne 2,6 sekundy.

Model Linear SVM bol trénovaný s parametrom $C = 1,0$ a `class_weight = balanced`. Hodnota $C = 1,0$ predstavuje štandardné nastavenie rovnovážnej regularizácie a bola ponechaná ako predvolená, keďže model dosahoval dobré výsledky bez ďalšieho doladovania. Čas tréovania bol približne 2,4 sekundy.

Model Naive Bayes bol trénovaný s parametrom vyhladzovania `alpha = 0,1`. Nižšia hodnota parametra oproti predvolenému nastaveniu (1,0) znižuje mieru vyhladzovacieho efektu, čo sa ukázalo vhodným pri bohatom slovníku TF-IDF. Čas tréovania bol kratší ako 0,1 sekundy.

Tabuľka 4 – 10 Finálne metriky baseline modelov na validačnej množine

Metrika	Logistic Regression	Linear SVM	Naive Bayes
Accuracy	0,9479	0,9477	0,9467
F1-score	0,7644	0,7578	0,7077
ROC-AUC	0,9696	0,9639	0,9504
Precision (toxická trieda)	0,71	0,72	0,80
Recall (toxická trieda)	0,83	0,80	0,63
TN (True Negative)	13 779	13 817	14 079
FP (False Positive)	556	518	256
FN (False Negative)	275	317	594
TP (True Positive)	1 348	1 306	1 029

Všetky tri modely boli natrénované v priebehu niekoľkých sekúnd. Najlepší výsledok spomedzi baseline modelov dosiahol Logistic Regression s hodnotou F1-score 0,7644 a zároveň najvyššou hodnotou ROC-AUC 0,9696. Model Linear SVM dosiahol druhý najlepší výsledok s hodnotami F1-score 0,7578 a ROC-AUC 0,9639.

Model Naive Bayes dosiahol najvyššiu hodnotu Precision 0,80, avšak zároveň mal najnižší Recall 0,63 a najnižšie hodnoty F1-score 0,7077 a ROC-AUC 0,9504, pričom nesprávne označil 594 toxických komentárov ako netoxické. Napriek vysokým hodnotám ROC-AUC všetkých troch modelov zostávajú hodnoty F1-score výrazne nižšie, čo odráža ťažkosti pri klasifikácii s pevným prahom 0,5 pri nevyvážených triedach.

4.5 Hodnotenie a porovnanie všetkých modelov

4.5.1 Celkové porovnanie podľa F1-score

Ako hlavná hodnotiacia metrika bol zvolený F1-score, pretože dataset obsahuje výrazne nevyvážené triedy (10,2 % toxických komentárov). Samotná accuracy by v takomto prípade mohla viesť k zavádzajúcim výsledkom, keďže model môže dosahovať vysokú accuracy aj pri nedostatočnej detekcii toxických komentárov. F1-score predstavuje harmonický priemer precision a recall, a preto vhodnejšie hodnotí schopnosť modelu zachytiť toxický obsah pri zachovaní nízkeho počtu FP.

Pre všetky modely bola predikcia určená výberom triedy s najvyššou predikovanou pravdepodobnosťou (argmax). Keďže úloha je binárna klasifikácia, toto je ekvivalentné použitiu prahu 0,5. Prah 0,5 bol zvolený jednotne pre všetky modely, čo zodpovedá štandardnej praxi používanej v súvisiacich prácach [8, 13, 20] a umožňuje priame porovnanie výsledkov.

Najlepší výsledok spomedzi všetkých modelov dosiahol model BERT s hodnotou F1-score 0,8427. Všetky štyri transformerové modely výrazne prekonal baseline modely. Rozdiel medzi najlepším transformerovým modelom (BERT, F1 0,8427) a najlepším baseline modelom (Logistic Regression, F1 0,7644) bol 0,0783, čo zodpovedá zlepšeniu o 10,2 %.

Tabuľka 4 – 11 Porovnanie všetkých modelov na validačnej množine Jigsaw

Model	Parametre	Accuracy	F1	ROC-AUC	Precision	Recall
BERT	110,0M	0,9683	0,8427	0,9864	0,85	0,83
RoBERTa	125,0M	0,9667	0,8370	0,9862	0,83	0,84
DistilBERT	67,0M	0,9663	0,8327	0,9841	0,84	0,82
ALBERT	11,7M	0,9658	0,8288	0,9842	0,84	0,81
Logistic Regression	~0,05M	0,9479	0,7644	0,9696	0,71	0,83
Linear SVM	~0,05M	0,9477	0,7578	0,9639	0,72	0,80
Naive Bayes	~0,05M	0,9467	0,7077	0,9504	0,80	0,63

4.5.2 Kompromis medzi Precision a Recall

Medzi transformerovými modelmi možno pozorovať zaujímavý vzor:

- **BERT** má najvyššiu Precision (0,85) – model menej často nesprávne označuje netoxické komentáre ako toxické (238 FP).
- **RoBERTa** má najvyšší Recall (0,84) – model lepšie zachytáva toxické komentáre (260 FN oproti 268 pri modeli BERT).

To znamená, že výber medzi modelmi BERT a RoBERTa závisí od požiadaviek konkrétneho systému. Model BERT je vhodnejší v prípadoch, keď je dôležité minimalizovať FP, zatiaľ čo model RoBERTa je vhodnejší tam, kde je dôležité nezmeškať toxický obsah.

4.5.3 Praktické charakteristiky modelov

Tabuľka 4 – 12 Praktické charakteristiky transformerových modelov

Model	Parametre	Veľkosť	Inferencia	Priepustnosť
BERT	110,0M	440 MB	6,78 ms	147/s
RoBERTa	125,0M	500 MB	6,91 ms	145/s
DistilBERT	67,0M	255 MB	3,64 ms	274/s
ALBERT	11,7M	44,6 MB	7,42 ms	135/s

Model DistilBERT dosiahol rýchlosť inferencie 3,64 ms na komentár (274 komentárov za sekundu) pri veľkosti modelu 255 MB, čo predstavuje najlepší kompromis

medzi kvalitou a rýchlosťou spomedzi všetkých testovaných modelov. Pri zachovaní 98,8 % kvality modelu BERT ponúka približne dvojnásobnú rýchlosť inferencie a zaberá o 42 % menej miesta na disku.

Model ALBERT mal najmenšiu veľkosť zo všetkých modelov (44,6 MB), a preto je vhodný na použitie v zariadeniach s obmedzenou pamäťou. Napriek výrazne menšiemu počtu parametrov bola rýchlosť inferencie (7,42 ms) približne rovnaká ako v prípade modelu BERT (6,78 ms). Je to spôsobené architektúrou ALBERT, kde sú parametre zdieľané medzi vrstvami, preto zníženie počtu parametrov automaticky nevedie k zrýchleniu inferencie.

Modely BERT a RoBERTa dosiahli takmer rovnakú rýchlosť inferencie (6,78 ms a 6,91 ms), čo bolo očakávané, keďže ich architektúry sú veľmi podobné.

4.6 Testovanie trénovaných modelov na iných datasetoch

4.6.1 Externé datasety

Na overenie toho, ako dobre modely fungujú na dátach z iných domén, boli použité dva externé datasety bez dotrénovania.

Dataset **Civil Comments** pochádza z platformy Civil Comments, ktorá poskytovala nástroje na moderáciu online diskusií pre novinárske stránky [22]. Komentáre boli zbierané z novinových diskusií na rôznych webových stránkach a anotované prostredníctvom crowdsourcingu. Hodnotenie vykonávali bežní používatelia internetu, pričom každý komentár posudzovalo viacero anotátorov. Celkovo dataset obsahuje približne 1,8 milióna komentárov anotovaných podľa nasledujúcich atribútov toxicity: *toxicity*, *severe_toxicity*, *obscene*, *threat*, *insult*, *identity_attack* a *sexual_explicit*. Poskytuje mieru toxicity vyjadrenú podielom anotátorov, ktorí komentár označili ako toxický. Z dôvodu veľkosti datasetu bolo náhodne vybraných 20 000 komentárov (seed = 42) s podielom toxických príkladov 8,2 %. Spojitá miera toxicity bola binarizovaná prahom 0,5 (komentár sa považuje za toxický, ak ho ako toxický označila aspoň polovica anotátorov). Dataset je doménovo relatívne bližší k

trénovaciemu datasetu Jigsaw, keďže oba obsahujú komentáre z diskusných platforiem.

Dataset **TweetEval Offensive** bol vytvorený v rámci projektu TweetEval, ktorý združuje viaceré NLP úlohy postavené na dátach z platformy Twitter [23]. Dataset obsahuje príspevky anotované do dvoch tried: *offensive* a *not-offensive*. Komentáre z triedy *offensive* sa považujú za toxické (1) a komentáre z triedy *not-offensive* za netoxické (0). Predstavuje výrazne odlišnú doménu v porovnaní s predchádzajúcimi datasetmi, keďže tweety sú krátke, neformálne a často obsahujú slang, skratky a emoji. Na testovanie boli použité všetky dostupné splity datasetu (trénovací, validačný a testovací), čo predstavuje celkovo 14 100 príkladov s podielom toxických komentárov 32,9 %.

4.6.2 Výsledky a interpretácia

Tabuľka 4–13 F1-score modelov na troch datasetoch

Model	Jigsaw (trénované)	Civil Comments	TweetEval
BERT	0,8427	0,5169	0,6595
RoBERTa	0,8370	0,5323	0,6430
DistilBERT	0,8327	0,5305	0,6463
ALBERT	0,8288	0,5203	0,6272
Logistic Regression	0,7644	0,4529	0,5724
Linear SVM	0,7578	0,4373	0,5515
Naive Bayes	0,7077	0,2331	0,3863

Transformerové modely zaznamenali nasledujúci pokles na Civil Comments: BERT F1 0,5169 (−38,7 %), RoBERTa F1 0,5323 (−36,4 %), DistilBERT F1 0,5305 (−36,3 %), ALBERT F1 0,5203 (−37,2 %). Na TweetEval: BERT F1 0,6595 (−21,7 %), RoBERTa F1 0,6430 (−23,2 %), DistilBERT F1 0,6463 (−22,4 %), ALBERT F1 0,6272 (−24,3 %).

Baseline modely zaznamenali výraznejší pokles, na Civil Comments: Logistic Regression F1 0,4529 (−40,7 %), Linear SVM F1 0,4373 (−42,3 %), Naive Bayes F1 0,2331 (−67,1 %). Na TweetEval: Logistic Regression F1 0,5724 (−25,1 %), Linear


SVM F1 0,5515 (−27,2 %), Naive Bayes F1 0,3863 (−45,4 %).

Tabuľka 4 – 14 Doplnkové metriky modelov na externých datasetoch

Model	Accuracy	F1	ROC-AUC	Precision	Recall
Civil Comments					
BERT	0,9329	0,5169	0,9218	0,63	0,44
RoBERTa	0,9319	0,5323	0,9161	0,61	0,47
DistilBERT	0,9327	0,5305	0,9102	0,62	0,47
ALBERT	0,9304	0,5203	0,9104	0,59	0,46
Logistic Regression	0,9030	0,4529	0,8410	0,42	0,49
Linear SVM	0,9038	0,4373	0,8237	0,42	0,46
Naive Bayes	0,9168	0,2331	0,7605	0,47	0,15
TweetEval Offensive					
BERT	0,8001	0,6595	0,8447	0,75	0,59
RoBERTa	0,7982	0,6430	0,8435	0,77	0,55
DistilBERT	0,7971	0,6463	0,8356	0,76	0,56
ALBERT	0,7935	0,6272	0,8382	0,77	0,53
Logistic Regression	0,7547	0,5724	0,7629	0,67	0,50
Linear SVM	0,7550	0,5515	0,7551	0,69	0,46
Naive Bayes	0,7314	0,3863	0,7250	0,78	0,26

Doplnkové metriky (tabuľka 4 – 14) odhaľujú dôležitý rozdiel medzi oboma externými datasetmi. Zatiaľ čo F1-score modelu BERT na datasete Civil Comments klesol o 38,7 % (z 0,8427 na 0,5169), hodnota ROC-AUC klesla len o 6,5 % (z 0,9864 na 0,9218). To naznačuje, že model si na tejto doméne zachoval schopnosť rozlišovať medzi triedami, a výrazný pokles F1 je spôsobený najmä nevhodnosťou pevného prahu 0,5 pri odlišnom rozložení tried, čo potvrdzuje aj pokles recall (z 0,83 na 0,44) pri zachovaní vyššej precision. Naproti tomu na datasete TweetEval Offensive klesla aj ROC-AUC výraznejšie (o 14,4 % na 0,8447), čo poukazuje na skutočný posun domény, a nie len na problém s prahom. Z hľadiska ROC-AUC, ktorá nezávisí od klasifikačného prahu, dosiahol na oboch externých datasetoch najvyššie hodnoty model BERT.

Hodnoty accuracy na externých datasetoch nie sú navzájom priamo porovnateľné, keďže datasety majú odlišný podiel toxických príkladov (Civil Comments 8,2 %, TweetEval 32,9 %); vysoká accuracy na Civil Comments tak odráža najmä prevahu netoxickéj triedy, nie kvalitu detekcie.



Obrázok 4 – 2 F1-score transformeroých a baseline modelov na troch datasetoch: Jigsaw (trénovací), Civil Comments a TweetEval

Hoci model RoBERTa dosiahol na datasete Civil Comments vyšší F1-score ako model BERT (0,5323 oproti 0,5169), podľa ROC-AUC si najvyššiu rozlišovaciu schopnosť na tejto doméne zachoval model BERT (ROC-AUC 0,9218 oproti 0,9161 pre RoBERTa). Rozdiel vo F1 na datasete Civil Comments v prospech modelu RoBERTa je preto skôr dôsledkom interakcie s pevným prahom pri odlišnom rozložení tried než systematicky lepšej schopnosti fungovať na iných doménach.

Väčší pokles na datasete Civil Comments v porovnaní s TweetEval možno vysvetliť dvoma faktormi. Po prvé, Civil Comments používa priebežné hodnotenie toxicity získané od viacerých anotátorov, zatiaľ čo dataset Jigsaw obsahuje výhradne binárne značky, čo vedie k odlišnému rozloženiu hraničných prípadov. Po druhé, podiel toxických príkladov v Civil Comments (8,2 %) je ešte nižší ako v datasete Jigsaw (10,2 %), čo negatívne ovplyvňuje hodnotu F1-score pri pevnom klasifikačnom prahu. Vyšší podiel toxických príkladov v datasete TweetEval (32,9 %) naopak prispieva k vyšším hodnotám F1-score napriek výrazne odlišnej doméne tweetov.

Napriek tomu, že výkonnosť modelov klesla, transformerové modely výrazne prekonávajú baseline modely aj na externých datasetoch, čo potvrdzuje praktickú hodnotu transformerov pri detekcii toxicity.

4.7 Manuálna analýza chýb modelu BERT

Na hlbšie pochopenie obmedzení modelu BERT bola vykonaná manuálna analýza chýb na validačnej množine. Model BERT bol zvolený ako základný referenčný model s najlepším výsledkom F1-score na validačnej množine. Z 15 958 príkladov model spravil 506 chýb (3,17 %), z toho 268 FN a 238 FP.

4.7.1 Istota modelu pri chybách

Tabuľka 4 – 15 Istota modelu BERT pri chybných predikciách

Typ chyby	Veľmi istý	Istý	Neistý	Spolu
FN ($p < 0,1$ / 0,1–0,3 / 0,3–0,5)	233	28	7	268
FP ($p \geq 0,9$ / 0,7–0,9 / 0,5–0,7)	135	82	21	238

Až 87 % všetkých FN má predpokladanú pravdepodobnosť toxicity nižšiu ako 10 %. To znamená, že model sa jednoznačne mýlil, a nie že to bolo na hrane. Tieto chyby predstavujú systematické obmedzenia modelu, ktoré nie je možné odstrániť len úpravou klasifikačného prahu.

4.7.2 Analýza FN podľa podtypov toxicity

Tabuľka 4 – 16 Miera vynechania podľa podtypu toxicity – model BERT

Podtyp toxicity	Celkom	Vynechané	Miera vynechania
severe_toxic	143	0	0,0 %
obscene	826	20	2,4 %
insult	778	27	3,5 %
threat	42	3	7,1 %
identity_hate	132	11	8,3 %
toxic (všeob.)	1 525	235	15,4 %

Model nikdy nezlyhal pri detekcii kategórie `severe_toxic` (0/143 prípadov) a len veľmi zriedka pri kategóriách s jasnými lexikálnymi signálmi. Väčšina chýb (235 z

268, približne 88 %) patrí do všeobecnej kategórie `toxic` bez ďalšieho podtypu, teda do prípadov, kde toxicita nie je sprevádzaná priamymi hrubými slovami.

Keďže jeden komentár môže patriť do viacerých kategórií súčasne, súčet príkladov po podtypoch (3 446) presahuje celkový počet toxických komentárov vo validačnej množine (1 623).

4.7.3 Kategórie FN

Kategória 1: Pochovaná toxicita v dlhom texte

Niektoré komentáre obsahujú dlhý neutrálny úvod, pričom toxický element sa nachádza až na konci textu. Nasledujúci príklad obsahuje úvod o austrálskej samospráve zakončený toxickou časťou. Z dôvodu dĺžky je ukázaná len časť komentára:

„The various local government areas pages only list them. I was thinking something like that. These three paragraphs are from a couple of papers I wrote [...] (Fuck you!)“

[$p_{\text{toxic}} = 0,000$; v datasete označené ako `obscene`]

Toxická časť komentára sa pravdepodobne nachádzala za hranicou 256 tokenov a bola orezaná, preto model spracoval len neutrálnu časť textu a označil komentár ako netoxický.

Kategória 2: Agresia vyjadrená veľkými písmenami

V niektorých prípadoch je toxicita vyjadrená výlučne použitím veľkých písmen, bez akýchkoľvek hrubých slov:

„SO EITHER DISCUSS IT OR BE BANNED FROM WIKIPEDIA.“

[$p_{\text{toxic}} = 0,000$; v datasete označené ako `toxic`]

Variant `bert-base-uncased` prevádza celý vstup na malé písmená, čím sa informácia o veľkosti písmen úplne stráca. Pre človeka je tento komentár jednoznačne agresívny, avšak model po predspracovaní textu nevidí žiadny toxický signál.

Kategória 3: Pasívna agresia a sarkazmus

Niektoré komentáre sú toxické napriek tomu, že neobsahujú žiadne hrubé slová:

„The only help I need is the removal of deletionist administrators such as yourself.“

[$p_{\text{toxic}} = 0,000$; v datasete označené ako **toxic**]

Komentár je zjavne nepriateľský, avšak model sa zameriava predovšetkým na lexikálne signály toxicity a nedokáže zachytiť nepriamy útok vyjadrený zdvorilým jazykom.

Kategória 4: Vulgárny jazyk v neagresívnom kontexte

Niektoré komentáre obsahujú vulgárny jazyk, ktorý však nie je použitý ako útok voči inej osobe:

„Although shitting on me isnt exactly making me want to demand that the withdrawal be respected.“

[$p_{\text{toxic}} = 0,000$; v datasete označené ako **toxic**]

Autor opisuje, ako sa k nemu správajú, a tento vulgárny výraz nie je namierený proti nikomu. Pravdepodobne v tomto prípade nejde o chybu modelu, ale o prípadnú nesprávnu anotáciu v datasete Jigsaw.

Kategória 5: Skryté hrozby

Niektoré komentáre obsahujú priame hrozby bez použitia akýchkoľvek hrubých slov:

„Block or I will put a virus into Wikipedia.“

[$p_{\text{toxic}} = 0,000$; v datasete označené ako **threat**]

Komentár jasne obsahuje hrozbu zlomyseľného úmyslu, model ho však klasifikoval ako netoxický. Model hľadá prítomnosť jasných lexikálnych signálov a nie je schopný rozpoznať, že samotná opísaná činnosť je toxická.

4.7.4 Analýza FP

Na rozdiel od FN, netoxické komentáre v datasete Jigsaw nemajú ďalšie podkategórie, preto analýza vychádza priamo z manuálneho prehľadu chybných predikcií.

Kategória 1: Sporná anotácia datasetu

Niektoré komentáre obsahujú jednoznačné urážky adresované konkrétnej osobe, napriek tomu sú v datasete označené ako netoxické:

„Compromise. Here’s the deal: I’ll stop vandalising if you stop being such a little pussy.“

[$p_{\text{toxic}} = 1,000$; v datasete označené ako netoxické]

Pravdepodobne nejde o chybu modelu, ale o nesprávnu anotáciu v datasete Jigsaw.

Kategória 2: Vulgárny jazyk bez agresívneho zámeru

Niektoré komentáre obsahujú vulgárny jazyk, ktorý však nie je namierený voči nikomu konkrétnemu:

„LOL PENIS! LOL! I AM TALKING TO YOU SO THIS SHIT IS NOT VANDALISING!“

[$p_{\text{toxic}} = 1,000$; v datasete označené ako netoxické]

Model reagoval na prítomnosť vulgárnych výrazov a označil komentár ako toxický. Podobný problém sa vyskytol aj pri FN. Model má ťažkosti s vulgárnym jazykom použitým mimo agresívneho kontextu, pričom ho niekedy ignoruje a niekedy nesprávne klasifikuje ako toxický.

Kategória 3: Ironický alebo vtipný kontext

Niektoré komentáre obsahujú slová, ktoré môžu pôsobiť urážlivo, avšak sú použité vtipne alebo v ironickom kontexte:

„Wil Wheaton loves star wars you jerk“

[$p_{\text{toxic}} = 1,000$; v datasete označené ako netoxické]

Model nedokáže rozpoznať ironický alebo vtipný tón komentára a reaguje len na prítomnosť potenciálne urážlivého slova.

Kategória 4: Nezmyselný alebo náhodný obsah

Niektoré komentáre obsahujú opakujúce sa slová alebo náhodný text bez jasného kontextu:

„*MONKEY MONKEY MONEY MONKEY MONKEY*“

[$p_{\text{toxic}} = 1,000$; v datasete označené ako netoxické]

Model pravdepodobne reagoval na opakujúce sa slovo, avšak komentár neobsahuje žiadny útok ani hrozbu.

4.7.5 Závery analýzy chýb

Analýza chýb ukázala, že model BERT má problémy pri detekcii skrytej toxicity. Najčastejšie išlo o pasívnu agresiu, sarkazmus, skryté hrozby a toxicitu ukrytú v dlhom neutrálnom texte. Použitie variantu `bert-base-uncased` navyše spôsobuje stratu informácie o veľkých písmenách, čo vedie k nezachyteniu agresie vyjadrenej výlučne písaním veľkými písmenami.

Analýza FP ukázala, že nie všetky chyby sú spôsobené samotným modelom. Časť z nich pravdepodobne súvisí s nepresnosťami v anotácii datasetu Jigsaw, kde niektoré jednoznačne urážlivé komentáre boli označené ako netoxické.

5 Záver

Cieľom tejto práce bolo preskúmať možnosti využitia transformerových modelov na detekciu toxicity v online komentároch a vyhodnotiť ich výkonnosť na reálnych dátach. Na tento účel boli natrénované štyri transformerové modely (BERT, RoBERTa, DistilBERT a ALBERT) na datasete Jigsaw Toxic Comment Classification Challenge. Pre porovnanie boli natrénované aj tri klasické baseline modely (Logistic Regression, Linear SVM a Naive Bayes).

Výsledky experimentov potvrdili efektívnosť transformerových modelov pri detekcii toxicity. Najlepší výsledok dosiahol model BERT s hodnotou F1-score 0,8427. Pre porovnanie, najlepší klasický baseline model (Logistic Regression) dosiahol F1-score 0,7644, čo predstavuje relatívne zlepšenie o 10,2 % v prospech transformerových modelov. Všetky transformerové modely zároveň dosiahli hodnotu ROC-AUC vyššiu ako 0,98, čo potvrdzuje ich schopnosť spoľahlivo rozlišovať medzi toxickým a netoxickým obsahom.

Z praktického hľadiska sa ako najvyváženejšie riešenie ukázal model DistilBERT, ktorý pri zachovaní 98,8 % kvality modelu BERT ponúka takmer dvojnásobnú rýchlosť inferencie (3,64 ms oproti 6,78 ms) a zaberá o 42 % menej miesta na disku. Model ALBERT napriek najmenšiemu počtu parametrov (11,7 milióna) nevykazoval rýchlejšiu inferenciu ako BERT, čo potvrdilo, že zdieľanie parametrov medzi vrstvami znižuje pamäťové nároky, nie výpočtovú náročnosť.

Testovanie na externých datasetoch Civil Comments a TweetEval Offensive odhalilo relatívny pokles F1-score všetkých modelov pri prechode na inú doménu. Transformerové modely zaznamenali pokles v rozmedzí 36,3–38,7 % na Civil Comments a 21,7–24,3 % na TweetEval, pričom si napriek tomu udržali výrazný náskok pred baseline modelmi. Na datasete Civil Comments dosiahol najvyšší F1-score model RoBERTa (0,5323), no podľa ROC-AUC, ktorá nezávisí od klasifikačného prahu, si najlepšiu rozlišovaciu schopnosť na oboch externých datasetoch zachoval model BERT. Náskok RoBERTa vo F1 na Civil Comments je preto skôr dôsledkom interak-

cie s pevným prahom než systematicky lepšej generalizácie. Na trénovacej doméne Jigsaw boli výsledky modelov BERT a RoBERTa veľmi podobné (0,8427 oproti 0,8370), čo možno čiastočne vysvetliť tým, že hyperparametre trénovania boli zvolené podľa odporúčaní pôvodného článku o modeli BERT, čím mohla byť RoBERTa mierne znevýhodnená.

Manuálna analýza chýb modelu BERT odhalila päť hlavných kategórií FN: toxicitu ukrytú v dlhom texte, agresiu vyjadrenú výlučne veľkými písmenami, pasívnu agresiu a sarkazmus, vulgárny jazyk v neagresívnom kontexte a implicitné hrozby. Analýza FP zároveň ukázala, že časť chýb modelu súvisí s nepresnosťami v anotácii datasetu Jigsaw, a nie s chybou samotného modelu.

Na základe získaných výsledkov možno konštatovať, že transformerové modely predstavujú efektívny nástroj na automatickú detekciu online toxicity. Ich hlavným obmedzením zostáva citlivosť na doménu trénovacích dát a ťažkosti s implicitnými formami toxicity. Hodnotenie modelov prebehlo na validačnej množine, ktorá slúžila aj na výber najlepšej epochy transformerových modelov a niektorých hyperparametrov baseline modelov (C, alpha), čo môže mierne nadhodnocovať reportované výsledky v porovnaní s nezávislou testovacou množinou. Pre budúci výskum by bolo vhodné otestovať model **bert-base-cased**, ktorý by zachoval informáciu o veľkosti písmen, zvýšiť maximálnu dĺžku sekvencie nad 256 tokenov, vyskúšať vyvažovanie tried alebo Focal Loss pre transformerové modely a experimentovať s modelmi s pokročilejším kontextovým porozumením jazyka, ako napríklad DeBERTa alebo RoBERTa-large.

Literatúra

- [1] Shahi, G. K., Majchrzak, T. A. Defining, Understanding, and Detecting On-line Toxicity: Challenges and Machine Learning Approaches. arXiv preprint arXiv:2509.14264. 2025. DOI: <https://doi.org/10.48550/arXiv.2509.14264>
- [2] Arif, A., Qadir, M. A., Martins, R. S., Khuwaja, H. M. A. The Impact of Cyberbullying on Mental Health Outcomes Amongst University Students: A Systematic Review. *PLOS Mental Health*, 1(6):e0000166. 2024. DOI: <https://doi.org/10.1371/journal.pmen.0000166>
- [3] European Parliament and Council of the European Union. Regulation (EU) 2022/2065 on a Single Market For Digital Services (Digital Services Act). *Official Journal of the European Union*, L 277, s. 1–102. 2022. Dostupné na: <https://eur-lex.europa.eu/legal-content/SK/TXT/?uri=CELEX:32022R2065> [cit. 2026-05-29]
- [4] European Parliament and Council of the European Union. Regulation (EU) 2024/1689 on Artificial Intelligence (AI Act). *Official Journal of the European Union*, L 1689, 12.7.2024. Dostupné na: <https://eur-lex.europa.eu/legal-content/SK/TXT/?uri=CELEX:32024R1689> [cit. 2026-05-29]
- [5] EOOH.eu. *How Meta’s new Content Moderation Policies affect Gender-based Violence*. 2025. Dostupné na: <https://eooH.eu/articles/meta/online/gender/based/violence/content/moderation> [cit. 2026-05-29]
- [6] Bonetti, A., Martínez-Sober, M., Torres, J. C., Vega, J. M., Pellerin, S., Vila-Francés, J. Comparison between Machine Learning and Deep Learning Approaches for the Detection of Toxic Comments on Social Networks. *Applied Sciences*, 13(10):6038. 2023. DOI: <https://doi.org/10.3390/app13106038>
- [7] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., Polosukhin, I. Attention Is All You Need. In: *Advances in Neural*

-
- Information Processing Systems 30 (NeurIPS 2017)*, s. 5998–6008. 2017. DOI: <https://doi.org/10.48550/arXiv.1706.03762>
- [8] Fan, H., Du, W., Dahou, A., Ewees, A. A., Yousri, D., Abd Elaziz, M., Elsheikh, A. H., Abualigah, L., Al-qaness, M. A. A. Social Media Toxicity Classification Using Deep Learning: Real-World Application UK Brexit. *Electronics*, 10(11):1332. 2021. DOI: <https://doi.org/10.3390/electronics10111332>
- [9] Devlin, J., Chang, M. W., Lee, K., Toutanova, K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In: *Proceedings of NAACL-HLT 2019*, s. 4171–4186. 2019. DOI: <https://doi.org/10.18653/v1/N19-1423>
- [10] Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., Stoyanov, V. RoBERTa: A Robustly Optimized BERT Pretraining Approach. arXiv preprint arXiv:1907.11692. 2019. DOI: <https://doi.org/10.48550/arXiv.1907.11692>
- [11] Sanh, V., Debut, L., Chaumond, J., Wolf, T. DistilBERT, a Distilled Version of BERT: Smaller, Faster, Cheaper and Lighter. In: *5th Workshop on Energy Efficient Machine Learning and Cognitive Computing (NeurIPS 2019)*. arXiv preprint arXiv:1910.01108. 2019. DOI: <https://doi.org/10.48550/arXiv.1910.01108>
- [12] Lan, Z., Chen, M., Goodman, S., Gimpel, K., Sharma, P., Soricut, R. ALBERT: A Lite BERT for Self-supervised Learning of Language Representations. In: *International Conference on Learning Representations (ICLR 2020)*. 2020. DOI: <https://doi.org/10.48550/arXiv.1909.11942>
- [13] Sundelin, C. *Comparing Different Transformer Models' Performance for Identifying Toxic Language Online*. Master's thesis, Uppsala University. 2023. Dostupné na: <https://www.diva-portal.org/smash/get/diva2:1784346/FULLTEXT01.pdf> [cit. 2026-05-29]
-

-
- [14] Guillaume, P., Duchêne, C., Dehak, R. Hate Speech and Toxic Comment Detection Using Transformers. In: *Conférence francophone sur l'Extraction et la Gestion des Connaissances (EGC 2022), Workshop DL for NLP*, Blois, France. 2022. Dostupné na: https://www.researchgate.net/publication/360085544_Hate_Speech_and_Toxic_Comment_Detection_using_Transformers [cit. 2026-05-29]
- [15] Duchêne, C., Jamet, H., Guillaume, P., Dehak, R. A Benchmark for Toxic Comment Classification on Civil Comments Dataset. arXiv preprint arXiv:2301.11125. 2023. DOI: <https://doi.org/10.48550/arXiv.2301.11125>
- [16] Abusaqer, M., Saquer, J., Shatnawi, H. Efficient Hate Speech Detection: Evaluating 38 Models from Traditional Methods to Transformers. In: *Proceedings of the 2025 ACM Southeast Conference (ACMSE 2025)*, s. 203–214. 2025. DOI: <https://doi.org/10.1145/3696673.3723061>
- [17] Aklouche, B., Bazine, Y., Ghalia-Bououchma, Z. Offensive Language and Hate Speech Detection Using Transformers and Ensemble Learning Approaches. *Computación y Sistemas*, 28(3):1031–1039. 2024. DOI: <https://doi.org/10.13053/cys-28-3-4724>
- [18] Iftikhar, U., Ali, S. F., Mustafa, G., Bahar, N., Ishaq, K. Beyond Words: A Hybrid Transformer-Ensemble Approach for Detecting Hate Speech and Offensive Language on Social Media. *PeerJ Computer Science*, 11:e3214. 2025. DOI: <https://doi.org/10.7717/peerj-cs.3214>
- [19] Lashkarashvili, N., Tsintsadze, M. Toxicity Detection in Online Georgian Discussions. *International Journal of Information Management Data Insights*, 2(1):100062. 2022. DOI: <https://doi.org/10.1016/j.jjime.2022.100062>
- [20] Antypas, D., Camacho-Collados, J. Robust Hate Speech Detection in Social Media: A Cross-Dataset Empirical Evaluation. In: *The 7th Workshop on On-*

-
- line Abuse and Harms (WOAH)*, s. 231–242. 2023. DOI: <https://doi.org/10.18653/v1/2023.woah-1.25>
- [21] Jigsaw / Conversation AI. *Toxic Comment Classification Challenge*. Kaggle. 2018. Dostupné na: <https://www.kaggle.com/c/jigsaw-toxic-comment-classification-challenge> [cit. 2026-05-29]
- [22] Borkan, D., Dixon, L., Sorensen, J., Thain, N., Vasserman, L. Nuanced Metrics for Measuring Unintended Bias with Real Data for Text Classification. In: *Companion Proceedings of The 2019 World Wide Web Conference (WWW '19)*, s. 491–500. 2019. DOI: <https://doi.org/10.1145/3308560.3317593>
- [23] Barbieri, F., Camacho-Collados, J., Espinosa-Anke, L., Neves, L. TweetEval: Unified Benchmark and Comparative Evaluation for Tweet Classification. In: *Findings of the Association for Computational Linguistics: EMNLP 2020*, s. 1644–1650. 2020. DOI: <https://doi.org/10.18653/v1/2020.findings-emnlp.148>

Prílohy

Príloha A ZIP súbor s projektom v jazyku Python, ktorý realizuje experimenty.¹

Príloha B Používateľská príručka.

Príloha C Systémová príručka.

¹Prílohy sú dostupné elektronicky na: <https://github.com/kkuichi/am799jo>.

Príloha B

Táto používateľská príručka opisuje spôsob použitia priložených zdrojových kódov a reprodukcie experimentov realizovaných v bakalárskej práci.

Použitie

1. Rozbalte ZIP archív projektu stiahnutý z GitHubu.
2. Nainštalujte všetky potrebné knižnice uvedené v súbore `requirements.txt`.
3. Spustite požadovaný skript podľa typu experimentu (popis jednotlivých súborov sa nachádza v súbore `readme.txt`).
4. Výsledky experimentov budú uložené do príslušných výstupných súborov a priečinkov.

Poznámka

Dataseť **Civil Comments** a **TweetEval Offensive** sa načítavajú automaticky prostredníctvom knižnice **Hugging Face Datasets**.

Príloha C

Táto systémová príručka opisuje požiadavky na softvérové prostredie potrebné na spustenie priložených zdrojových kódov.

Požiadavky

- Python 3.10 alebo novší.
- Knižnice uvedené v súbore `requirements.txt`.